6M参数Latent模型
实现多风格互转训练和Few-Shot能力

```
2026-04-01 18:50:03,799 - INFO - Model params: 4,489,764
2026-04-01 18:50:05,457 - INFO - No checkpoint found, start from scratch.
2026-04-01 18:50:05,458 - INFO - LR warmup enabled: warmup_steps=210 start_factor=0.000 base_lr=5.000e-04
2026-04-01 18:51:05,448 - INFO - Epoch 1/40 | loss=160.1025 swd=0.4225 color=1.4995 idt=0.6249 idr=0.20 lr=8.33e-05 data
=0.5s comp=57.9s
2026-04-01 18:51:53,697 - INFO - Epoch 2/40 | loss=107.1865 swd=0.2881 color=0.9774 idt=0.7040 idr=0.20 lr=1.67e-04 data
=0.5s comp=46.2s
2026-04-01 18:52:41,997 - INFO - Epoch 3/40 | loss=98.1357 swd=0.2641 color=0.8919 idt=0.7212 idr=0.20 lr=2.50e-04 data=
0.5s comp=46.2s
2026-04-01 18:53:30,250 - INFO - Epoch 4/40 | loss=88.5808 swd=0.2371 color=0.8074 idt=0.7835 idr=0.20 lr=3.33e-04 data=
0.5s comp=46.2s
2026-04-01 18:54:18,536 - INFO - Epoch 5/40 | loss=87.2802 swd=0.2302 color=0.8096 idt=0.7550 idr=0.20 lr=4.17e-04 data=
0.5s comp=46.2s
2026-04-01 18:55:07,010 - INFO - Epoch 6/40 | loss=85.1772 swd=0.2229 color=0.7968 idt=0.7561 idr=0.20 lr=5.00e-04 data=
0.5s comp=46.4s
2026-04-01 18:55:55,265 - INFO - Epoch 7/40 | loss=81.8447 swd=0.2183 color=0.7490 idt=0.7374 idr=0.20 lr=4.92e-04 data=
0.5s comp=46.2s
2026-04-01 18:56:43,569 - INFO - Epoch 8/40 | loss=82.7039 swd=0.2205 color=0.7568 idt=0.7595 idr=0.19 lr=4.82e-04 data=
0.5s comp=46.2s
```

- SD模型体积不断扩张，Flux.2已经达到32B，对消费级硬件推理和训练造成极大的困难，即使是LORA也需要全量加载模型
- 为了固定的风格转换引入t2i的文字先验并无必要
- CUT确实取得了优秀的性能，但每种风格都需要单独训练，且显存占用大，对于需要正负样本的训练，batch不够大也会削减训练效果，训练成本过高
- VAE的潜空间性质良好，较小的推移不容易产生图像的崩坏，内容保持容易；32*32对应原图的Patch(8*8)

Fig. 1: **Patchwise Contrastive Learning for one-sided translation.** A generated **output patch** should appear closer to its **corresponding input patch**, in comparison to other **random patches**. We use a multilayer, patchwise contrastive loss, which maximizes *mutual information* between corresponding input and output patches. This enables one-sided translation in the unpaired setting.

al. [19] fails to synthesize realistic textures. Existing photo style transfer methods such as WCT^2 can only modify the color of the input image. Our method SinCUT outperforms CycleGAN and is comparable to a leading style transfer method [39],

为什么Latent上的风格分离困难--极低风格信噪比

- **信息折叠：高频风格信息坍缩**

  在高度压缩的Latent Space中，高频信息仍然存在但被折叠进通道间的复杂关系，
  经过实验，即使是协方差矩阵乃至二阶矩都难以将其解离。

- **瓶颈效应：KL 散度的信息剥夺**

  预训练 VAE 的 KL 散度强行将隐变量拉向标准正态分布。
  这种极端的信息瓶颈（Information Bottleneck）会优先抛弃高频纹理与笔触，
  导致潜空间内的“风格信噪比（Style SNR）”呈指数级衰减。

- **架构失效：宏观调制的无力感**

  在如此恶劣的低频语义空间中，传统的全局前馈网络或常规 AdaIN 算子犹如“盲人摸象”。
  它们无法在微弱的噪声中捕获风格，要么导致风格迁移无效（退化为 Identity）
  要么在强行放大信号时撕裂流形拓扑，导致解码崩溃。

Latent AdaCUT architecture

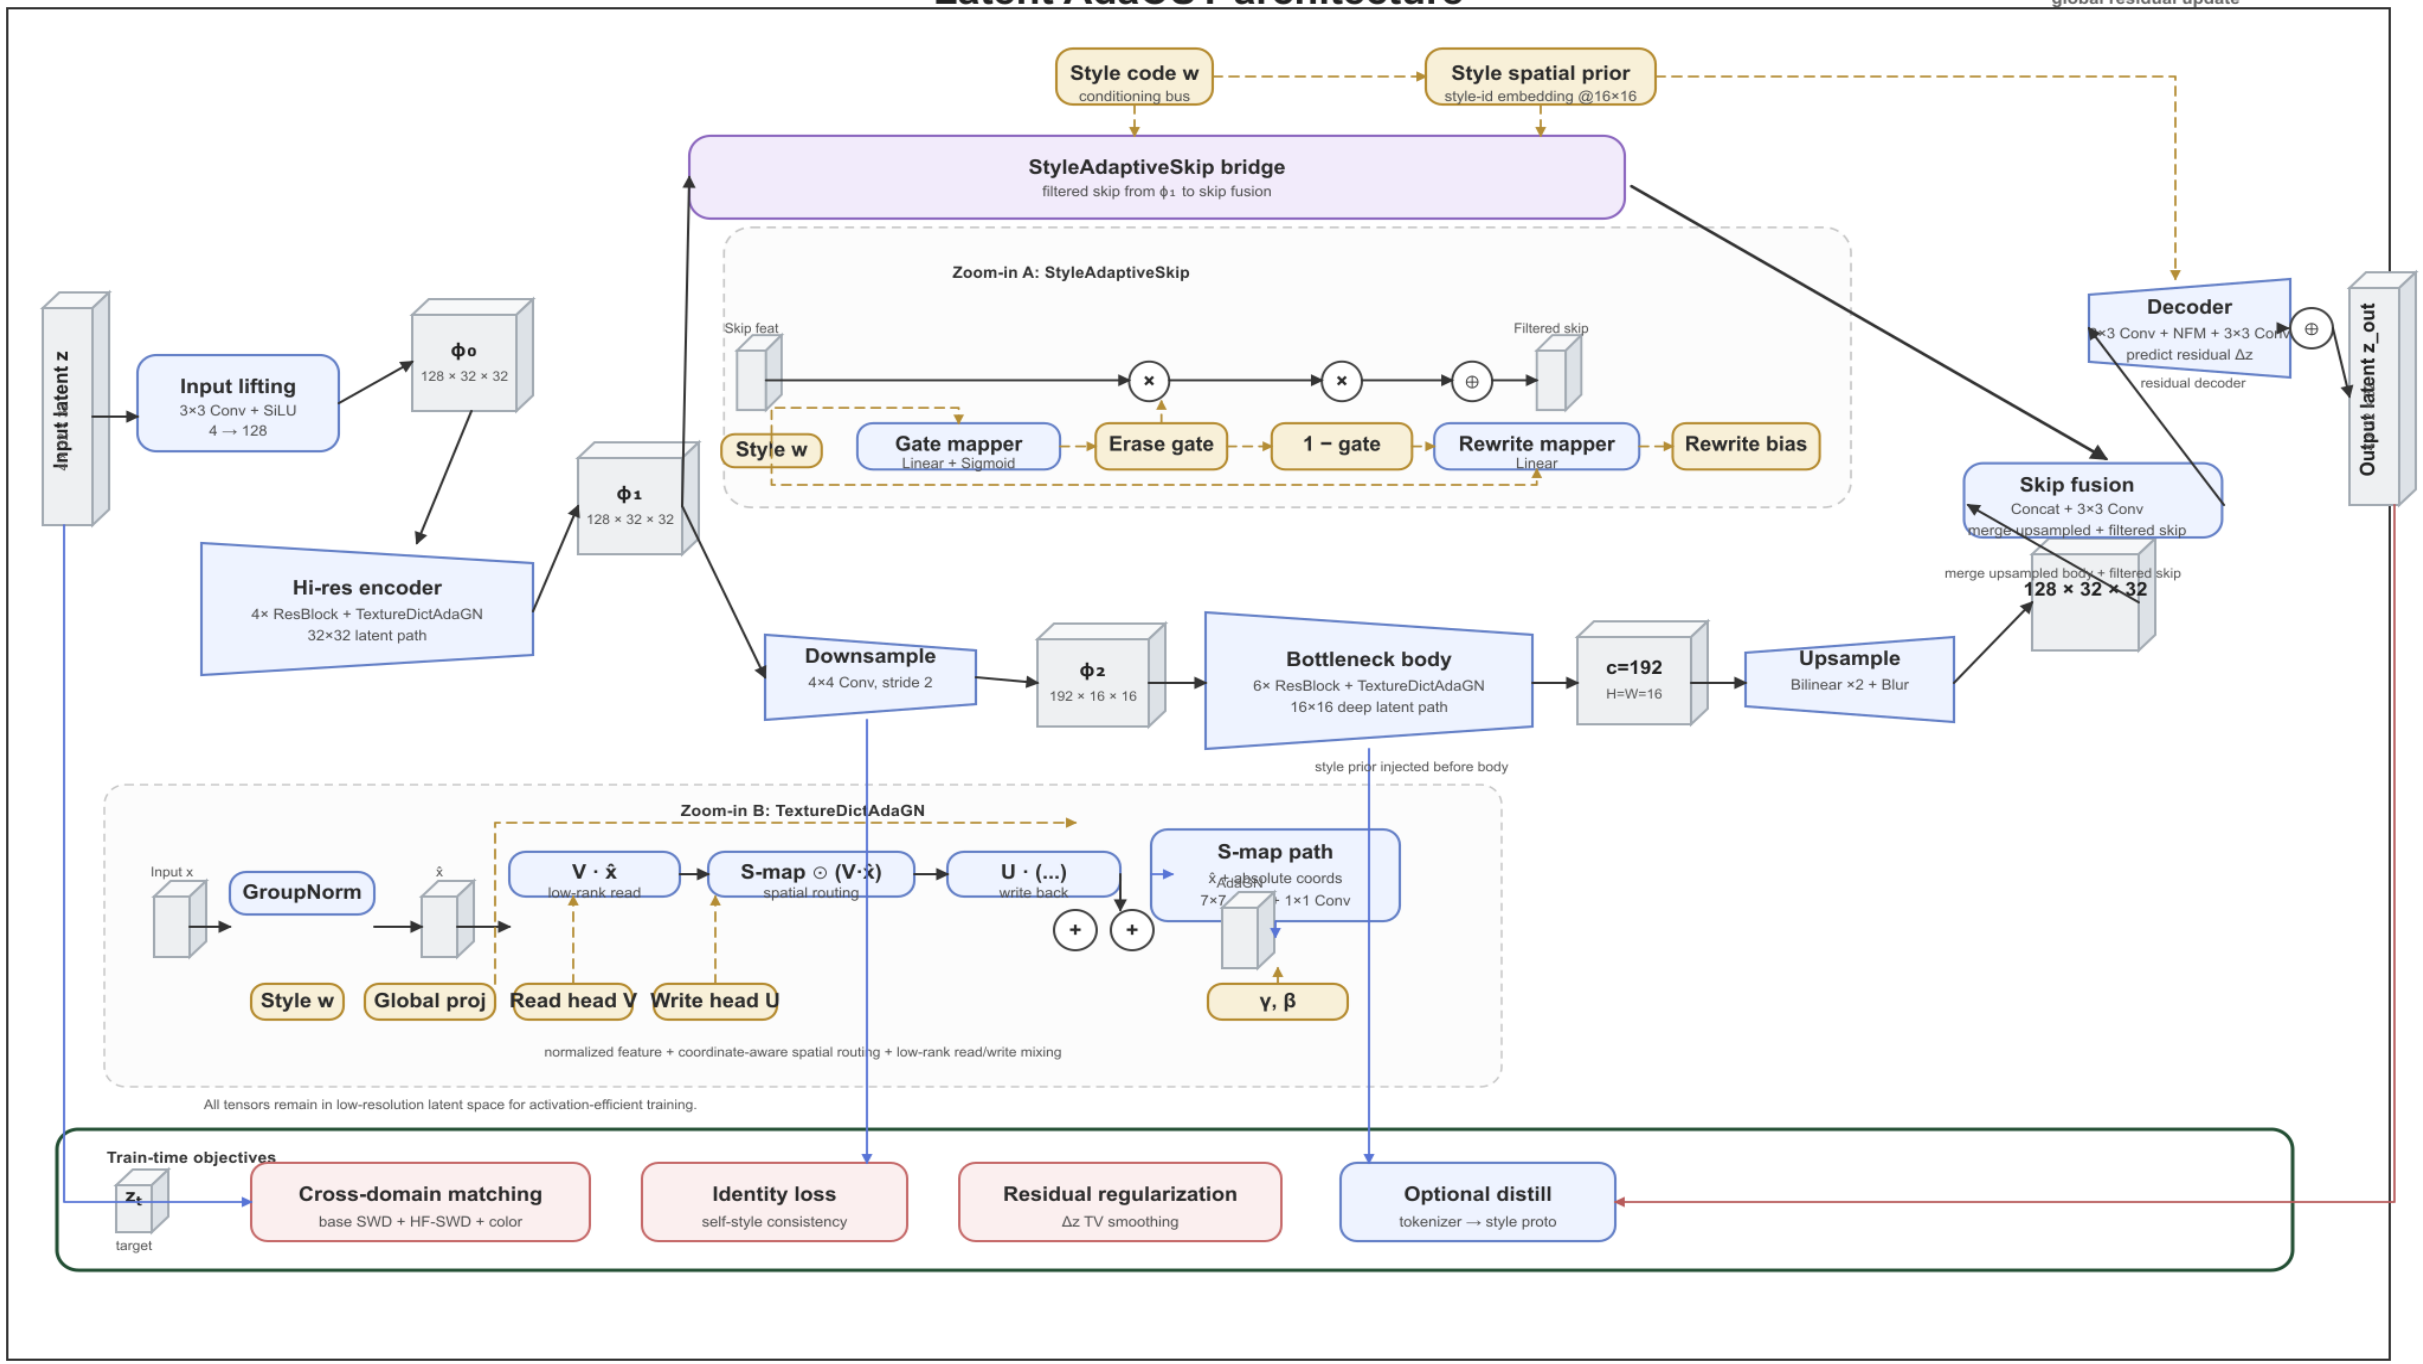

重返Attention——模型达标后的backbone新尝试

- 早期尝试并不成功。我们前期曾将 Cross-Attention 直接引入主干，但效果并不理想。回头看，这主要不是模块本身的问题，而是由于当时 loss 设计、风格监督频段和数据链路 尚未成熟，attention 难以稳定学习到有效的风格—内容对应关系。
- 训练框架成熟后，原有方案开始显得过重。随着 SWD / 高频约束 / skip 路由 / style injection 等基础设施逐渐稳定，早期为增强 AdaGN 局部修改能力而加入的 style dictionary 虽然有效，但其 参数量和计算开销偏大，不再是性价比最高的方案。
- 因此我们重新设计 backbone。同时，原先的 CNN Decoder 在笔触承载和局部重建上存在瓶颈，并更容易引入网格伪影。基于这些现象，我们重新引入 Cross-Attention，并将 decoder 改为 成对堆叠的 Window Attention。

- **Conv 负责局部结构编码，**
- **Global Cross-Attention 负责长程语义混合与风格注入，**
- **Window Attention Decoder 负责将全局重组后的特征稳定写回局部空间细节。**

Latent AdaCUT architecture

C–G–W backbone

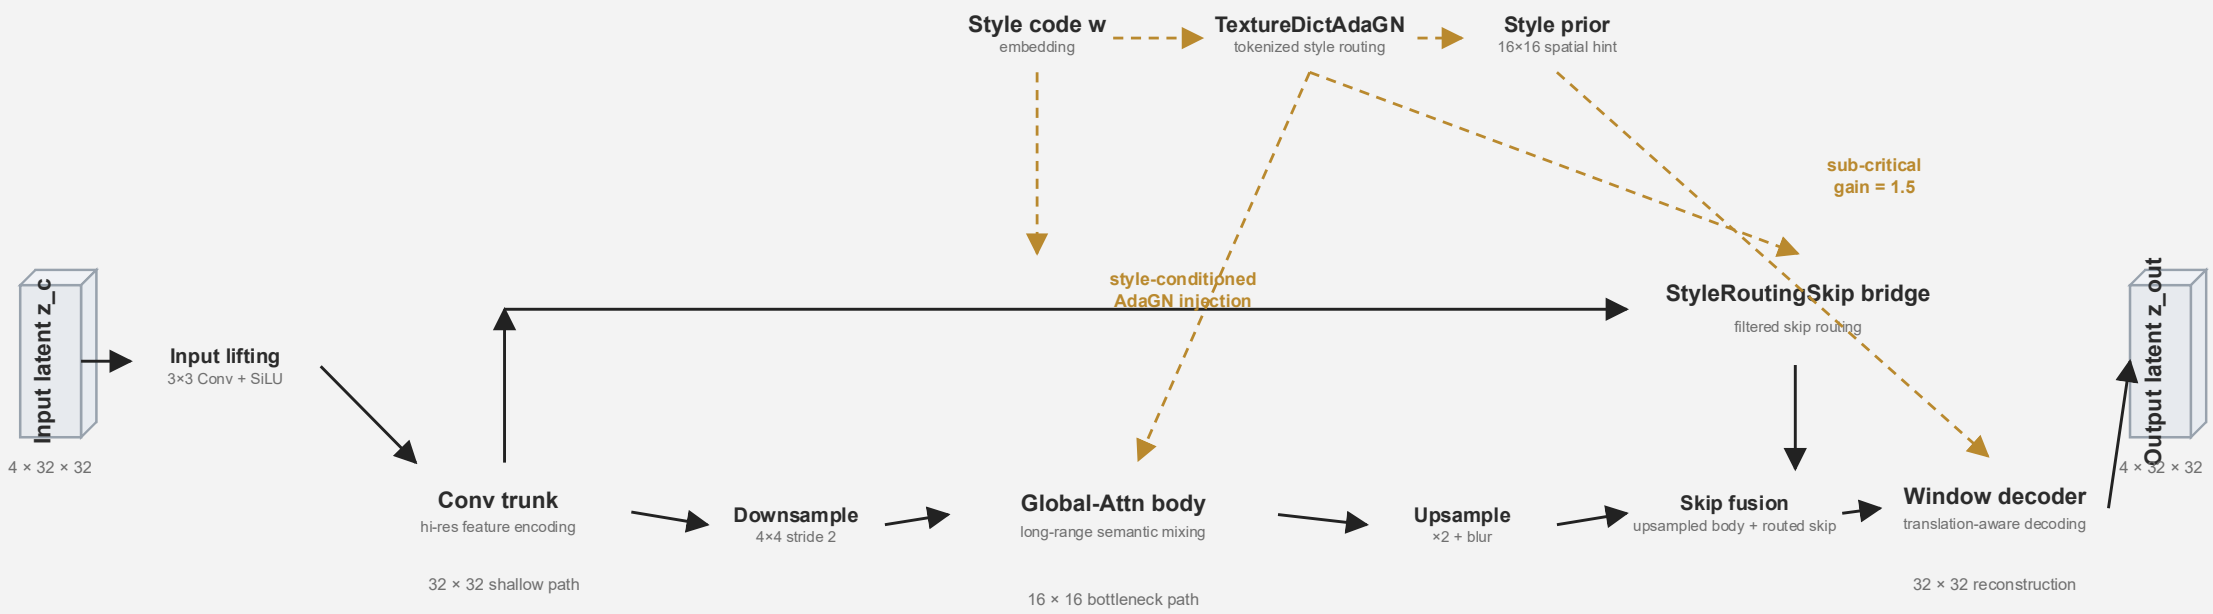

Current C–G–W layout

Conv trunk handles lifting and local encoding.
Global-Attn body builds long-range semantic dependency in the 16×16 latent space.
Window decoder restores local detail, while StyleRoutingSkip fuses filtered shallow features.

Style interface

TextureDictAdaGN tokenizes style information and routes it into the backbone.
Style code w modulates both the bottleneck body and the skip bridge.
The final output is produced by the decoder head without drawing an explicit ablation line.

为什么要用SWD（切片Wasserstein距离，推土机距离）

MSE之类的距离衡量，会锁死像素，让模型在惩罚下不敢做出改变；

SWD 最初是作为 **FID 的高效替代方案**，用于衡量两组图像分布的相似度。它比较的是 集合（生成图所有 Patch 的特征集合 vs 目标风格的所有 Patch 特征集合）。它不在乎纹理具体出现在哪个坐标，只在乎生成的纹理分布是否符合梵高的统计分布。这允许了模型进行“几何变形”的同时，精准注入纹理。
通过将最优传输（OT）问题降维至一维投影，我们将复杂的全局优化分解为简单的向量排序问题。

像素空间上为什么没人在训练中使用SWD

标准 SWD 需要对 (N_samples, Projections) 进行全量排序。在 $O(N \log N)$ 的复杂度下，作为评估指标尚可，但直接放入 Loss 函数中，会让训练速度不可接受。（N为样本数，8倍下采样后相当于像素空间的1/64，计算成本可接受）

传统的排序操作虽然是不可导的，但可以通过 **梯度直通** (Straight-Through Estimator, STE) 实现。然而，单纯的 STE 会导致严重的梯度方差，模型不仅训练极慢，还容易在极值点震荡。

我们的优化

$$\mathcal{L}_{SWD} = \sum_{j=1}^{S} \left\| \mathrm{Sort}\left(\mathrm{Proj}_{\theta_j}(P_{gen})\right) - \mathrm{Sort}\left(\mathrm{Proj}_{\theta_j}(P_{style})\right) \right\|_2^2$$

LUT缓存：在训练前对其进行预计算并缓存其排序分布。在训练过程中，模型仅需对当前生成图像的特征执行单次排序，并直接通过 index_select 操作查表获取目标分布的对应值。减少约一半开销

引入 **Soft-CDF 逼近算子**。利用 Sigmoid 函数替代硬排序的阶梯函数，将离散的排序操作转化为连续的可导映射。这不仅消除了梯度在极值点处的震荡，更实现了对纹理特征流形的连续、平滑引导。

$$CDF(g) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{I}(x_i \leq g)$$

$$\mathcal{L}_{Soft-SWD} = \sum_{j=1}^{S} \int_{\mathbb{R}} \left| \hat{\mathrm{CDF}}_{gen,\theta_j}(g) - \hat{\mathrm{CDF}}_{style,\theta_j}(g) \right|^2 dg$$

色彩对齐：统计约束 vs. 动态映射

- **Color Loss 做低频统计对齐。**
  我们先把 latent 四通道通过经验矩阵映射到可解释的亮度 / 色度统计空间，再只保留低频分量；随后对齐其 **均值、方差和亮度分位区间**。其中，均值主要对应亮度与色调基线，方差主要对应对比度与饱和度，亮度分位区间进一步约束曝光动态范围。当前 loss 侧实现中，确实是在低频 latent 上做 **mean / std + luma range** 约束，并对通道赋予不同权重。
- **MLP 直接学习风格条件的色彩映射。**
  与只靠 loss 反向拉回不同，第二种方法把色彩对齐前移到前向过程：由 style embedding 预测一个小型仿射映射
- $$z_{aligned} = W z_{norm} + \beta$$
- 其中 β 控制亮度 / 曝光基线，W 的对角线控制对比度与饱和度，非对角线负责跨通道耦合，例如曝光变化引起的色偏与饱和度联动。它本质上不是“匹配统计量”，而是学习一个**风格条件的动态调色器**。

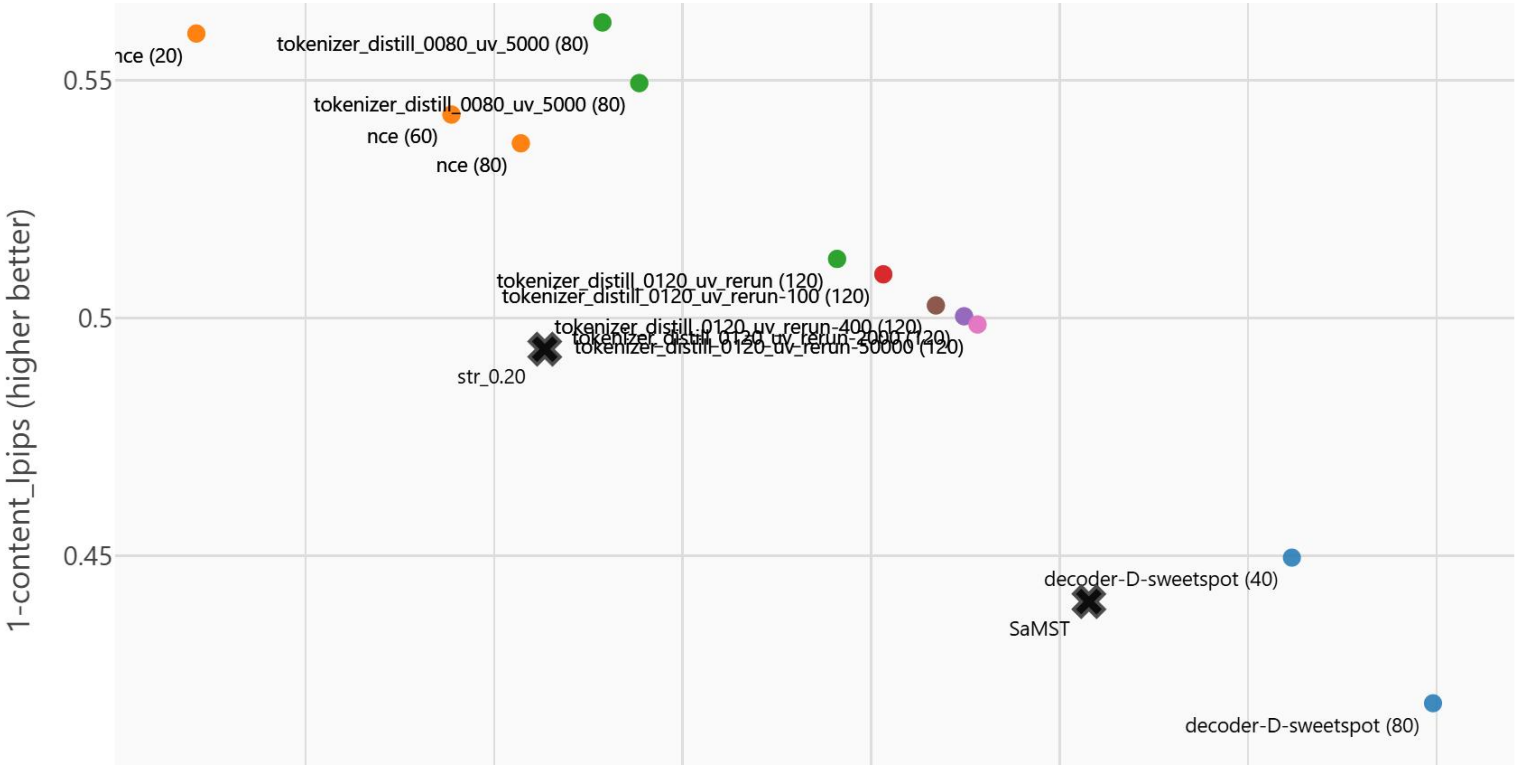

在clip_style – 1-content_lpips图上

性能明显优于sdedit，略优于SaMST (ACCV2024)

冻结主干只调整style_emb
也能让模型进步
且相同clip进步下lpips损失更小

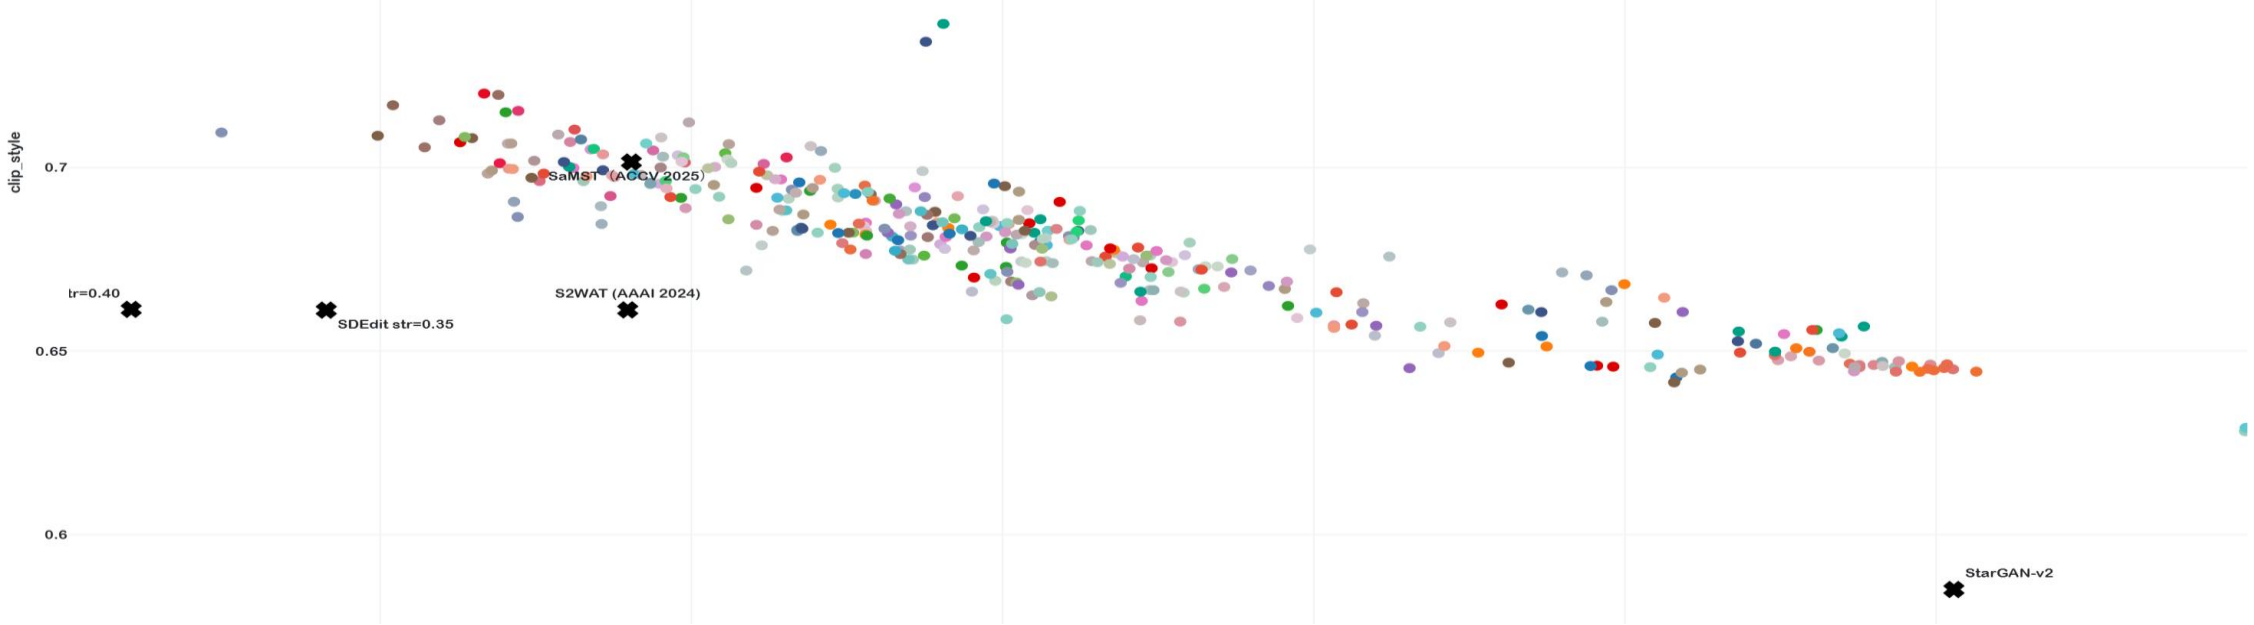

Method	Params ↓	CLIP-style ↑	CLIP-content ↑	Lpips-content ↓
StarGAN v2-latent	**≈ 43M**	0.585	**0.867**	**0.347**
SDEdit (str=0.35)	> 860M	0.661	0.615	0.609
SDEdit (str=0.40)	> 860M	0.661	0.594	0.640
SaMST	≈ 30M+	**0.702**	0.690	0.560
Ours	**≈ 6M**	0.680	**0.862**	**0.350**
Baseline (decoder-D-160, R=32)		0.687	0.726	0.517
w/o Global Residual		0.628*	**0.904***	**0.298***
w/o Adaptive Skip		0.686	0.713	0.534
w/o TextureDict		**0.692**	0.734	0.524

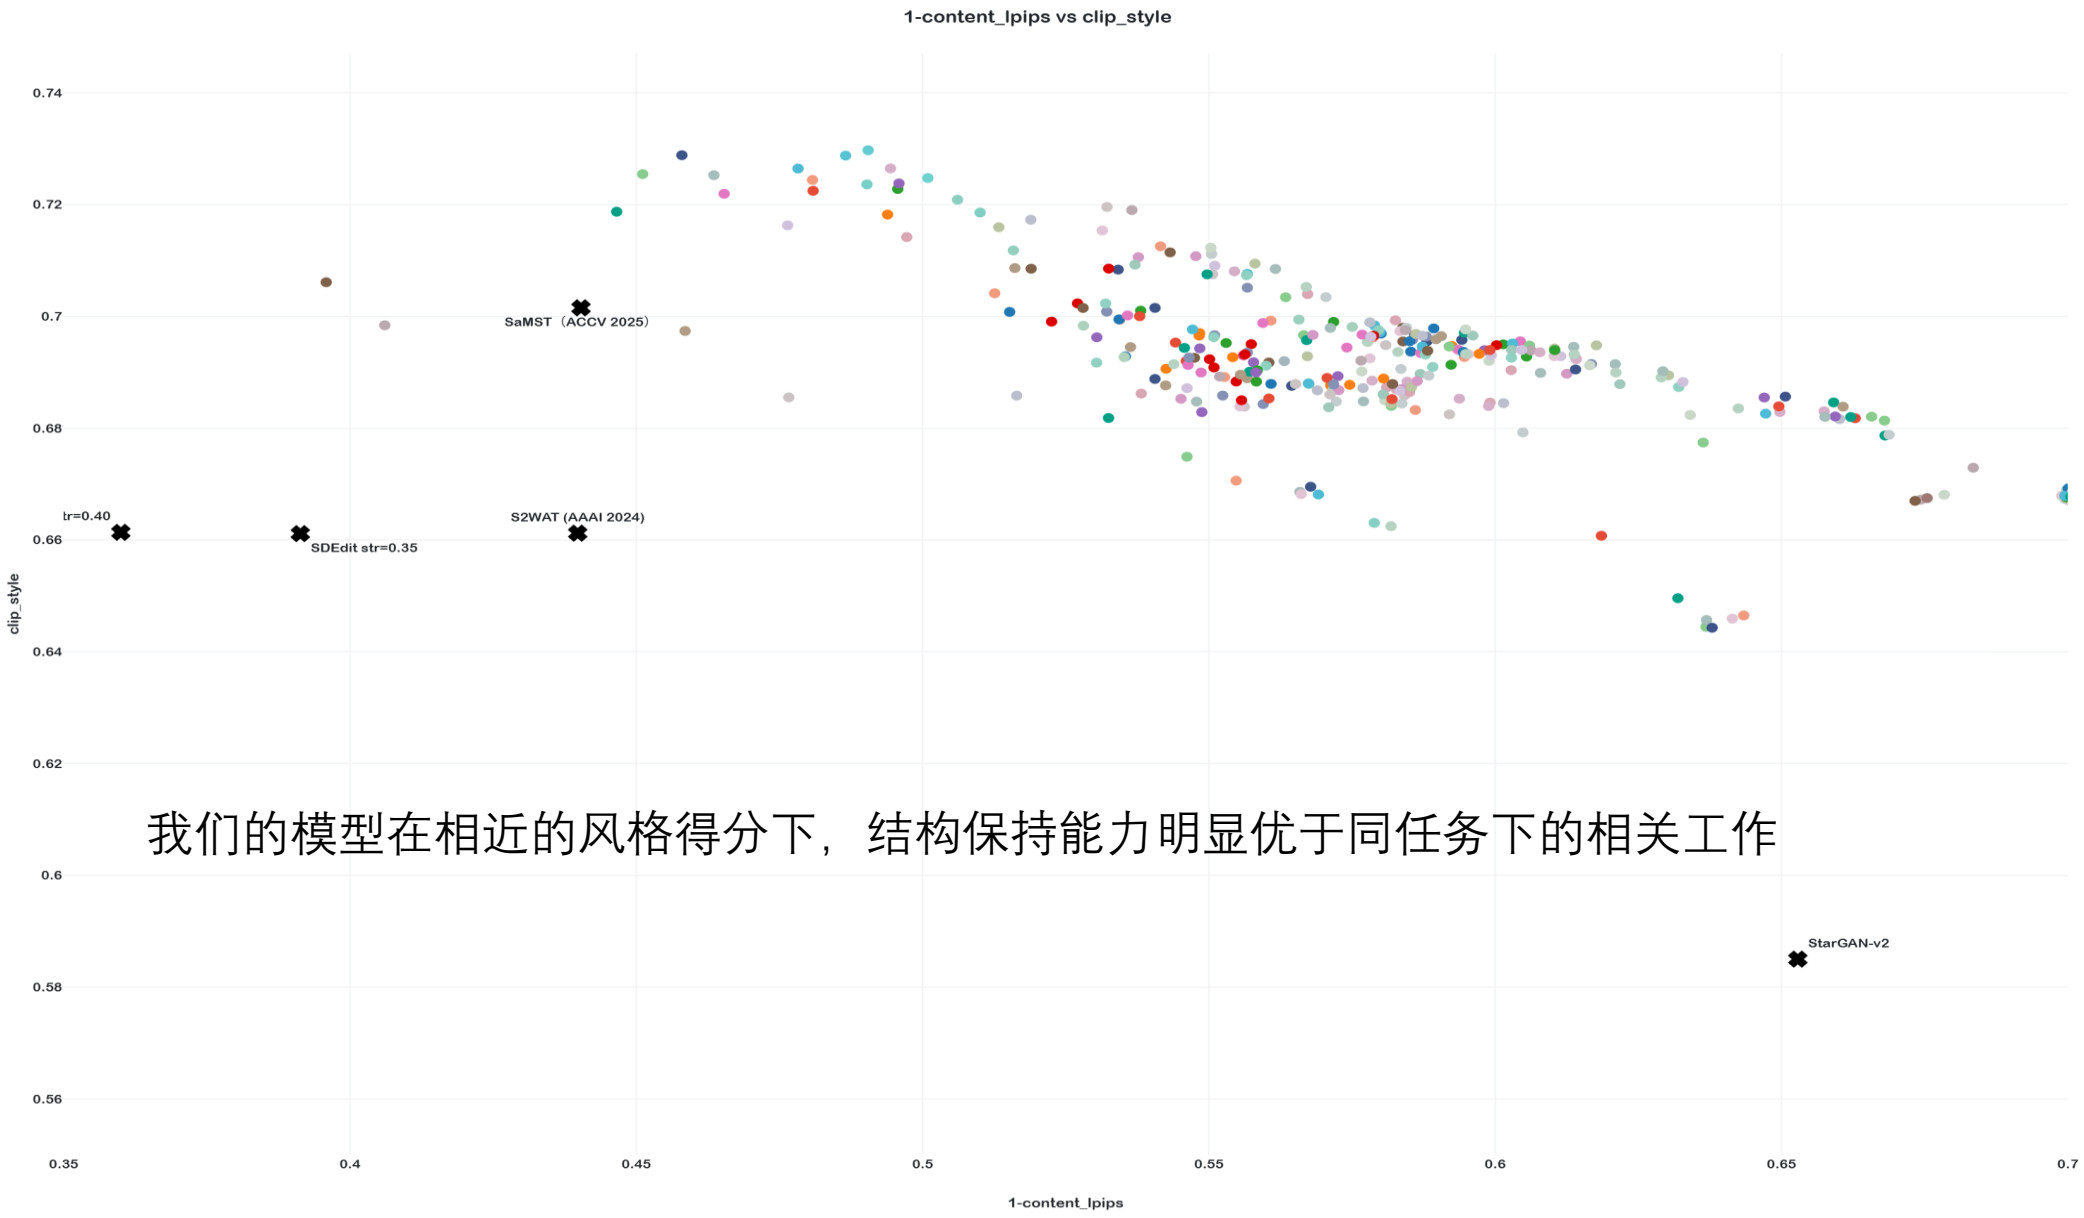

我们的模型在相近的风格得分下，结构保持能力明显优于同任务下的相关工作

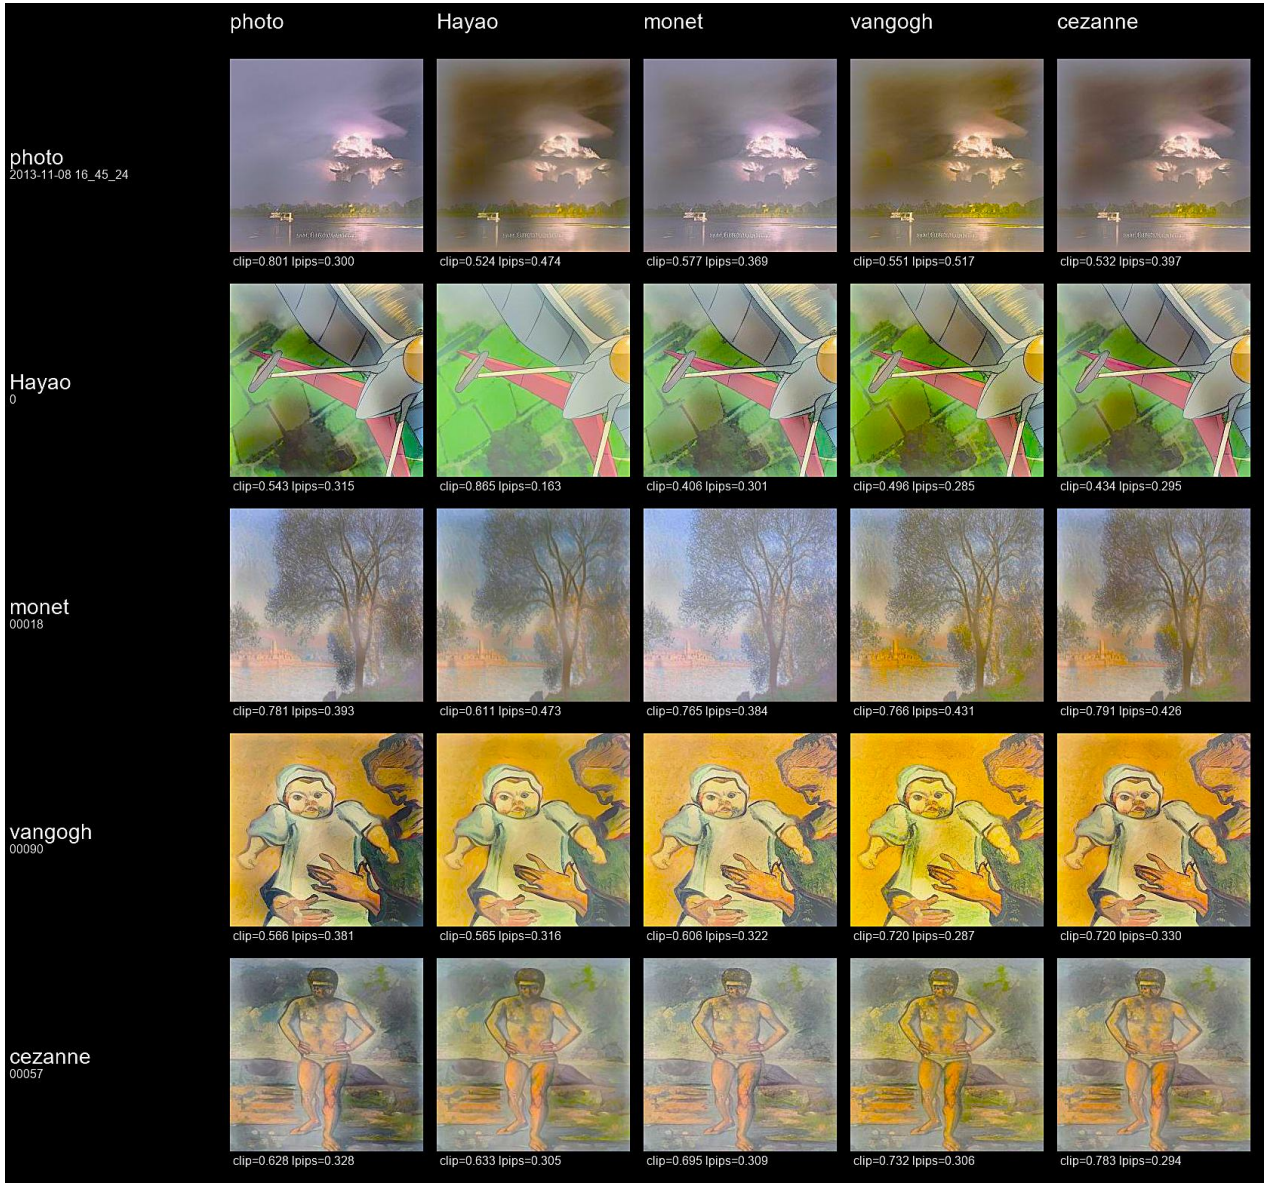

Ours, KID Delta Ratio =-13.1%

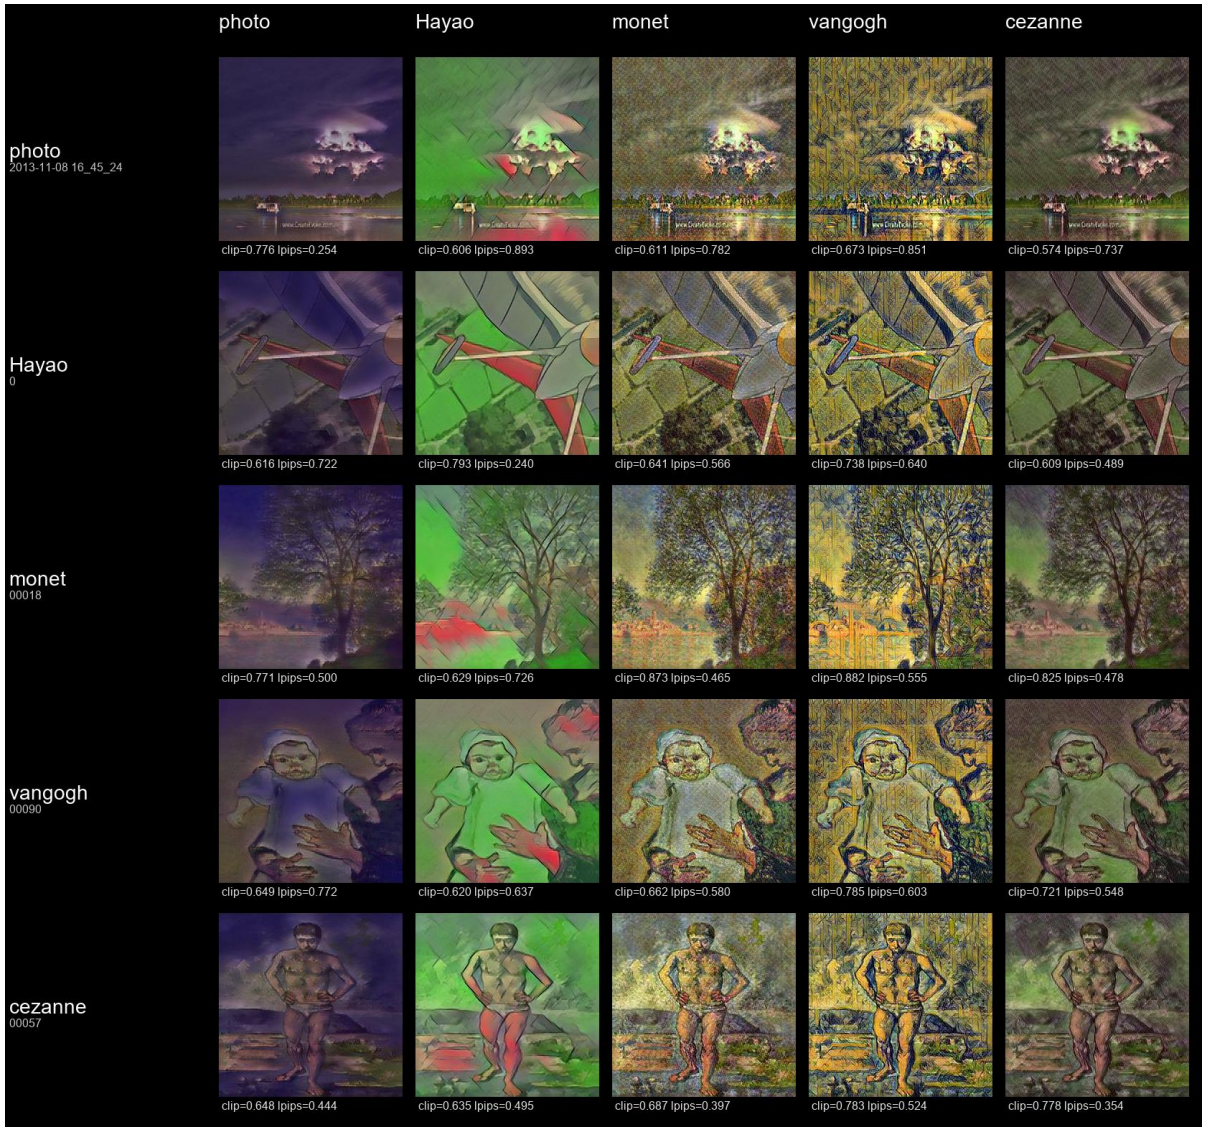

SaMST, KID Delta Ratio =-51.2%

- **Photo (基准)**：保留丰富的高频结构与写实光影。
- **Hayao (宫崎骏)**：线条明显，呈现柔和的**水彩平涂**与通透色块。
- **Monet (莫奈)**：边缘柔化，运用**细碎短笔触**营造印象派光影氛围。
- **Van Gogh (梵高)**：色调转换为标志性暖黄，展现**狂野的螺旋状厚涂笔触**。
- **Cézanne (塞尚)**：笔触更具**几何结构感**，通过块面堆叠重塑画面。

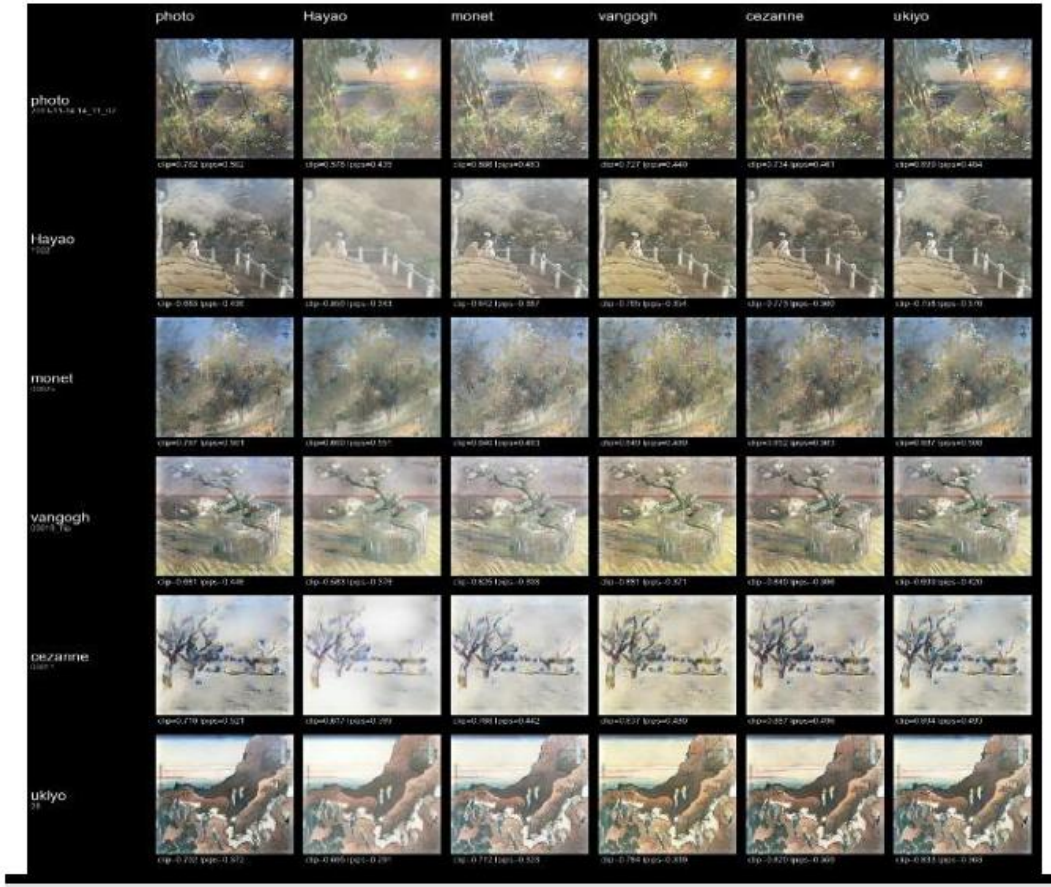

Direction	CLIP Style ↑	Content LPIPS ↓
Old art → ukiyo_e	**0.628238**	**0.324613**
ukiyo_e → Old art	**0.691235**	**0.251996**
photo → ukiyo_e	**0.609058**	**0.329195**
ukiyo_e → photo	**0.672280**	**0.249511**
ukiyo_e → ukiyo_e	**0.868146**	**0.251171**

我们使用富岳三十六景，6 张训练 30 张评估做浮世绘的 few-shot 训练，冻结主干仅训练 style_emb 部分，指标基本无劣化

Setting	5-style Original	6-style Overall	5-style Comparable	Δ Style (6 vs 5)	Δ LPIPS (6 vs 5)
All pairs overview	**0.679523**	**0.678289**	**0.679641**	**-0.001234**	**-0.012595**
Style transfer ability	**0.645539**	**0.649070**	**0.645643**	**+0.003531**	**-0.012705**
Identity reconstruction	**0.815459**	**0.824385**	**0.815632**	**+0.008926**	**-0.012330**
Photo → art performance	**0.611528**	**0.610926**	**0.611393**	**-0.000602**	**-0.000337**