6M 参数 Latent 模型
实现多风格互转训练和 Few-Shot 能力

```
2026-04-01 18:50:03,799 - INFO - Model params: 4,489,764
2026-04-01 18:50:05,457 - INFO - No checkpoint found, start from scratch.
2026-04-01 18:50:05,458 - INFO - LR warmup enabled: warmup_steps=210 start_factor=0.000 base_lr=5.000e-04
2026-04-01 18:51:05,448 - INFO - Epoch 1/40 | loss=160.1025 swd=0.4225 color=1.4995 idt=0.6249 idr=0.20 lr=8.33e-05 data
=0.5s comp=57.9s
2026-04-01 18:51:53,697 - INFO - Epoch 2/40 | loss=107.1865 swd=0.2881 color=0.9774 idt=0.7040 idr=0.20 lr=1.67e-04 data
=0.5s comp=46.2s
2026-04-01 18:52:41,997 - INFO - Epoch 3/40 | loss=98.1357 swd=0.2641 color=0.8919 idt=0.7212 idr=0.20 lr=2.50e-04 data=
0.5s comp=46.2s
2026-04-01 18:53:30,250 - INFO - Epoch 4/40 | loss=88.5808 swd=0.2371 color=0.8074 idt=0.7835 idr=0.20 lr=3.33e-04 data=
0.5s comp=46.2s
2026-04-01 18:54:18,536 - INFO - Epoch 5/40 | loss=87.2802 swd=0.2302 color=0.8096 idt=0.7550 idr=0.20 lr=4.17e-04 data=
0.5s comp=46.2s
2026-04-01 18:55:07,010 - INFO - Epoch 6/40 | loss=85.1772 swd=0.2229 color=0.7968 idt=0.7561 idr=0.20 lr=5.00e-04 data=
0.5s comp=46.4s
2026-04-01 18:55:55,265 - INFO - Epoch 7/40 | loss=81.8447 swd=0.2183 color=0.7490 idt=0.7374 idr=0.20 lr=4.92e-04 data=
0.5s comp=46.2s
2026-04-01 18:56:43,569 - INFO - Epoch 8/40 | loss=82.7039 swd=0.2205 color=0.7568 idt=0.7595 idr=0.19 lr=4.82e-04 data=
0.5s comp=46.2s
```

- SD 模型体积不断扩张， Flux.2 已经达到 32B ，对消费级硬件推理和训练造成极大的困难，即使是 LORA 也需要全量加载模型
- 为了固定的风格转换引入 t2i 的文字先验并无必要
- CUT 确实取得了优秀的性能，但每种风格都需要单独训练，且显存占用大，对于需要正负样本的训练， batch 不够大也会削减训练效果，训练成本过高
- VAE 的潜空间性质良好，较小的推移不容易产生图像的崩坏，内容保持容易；32*32 对应原图的 Patch(8*8)

Fig. 1: **Patchwise Contrastive Learning for one-sided translation.** A generated **output patch** should appear closer to its **corresponding input patch**, in comparison to other **random patches**. We use a multilayer, patchwise contrastive loss, which maximizes *mutual information* between corresponding input and output patches. This enables one-sided translation in the unpaired setting.

al. [19] fails to synthesize realistic textures. Existing photo style transfer methods such as WCT^2 can only modify the color of the input image. Our method SinCUT outperforms CycleGAN and is comparable to a leading style transfer method [39],

把工程动机再往前推一步：真正的问题是“结构–风格死锁”

这页只补论文 story，不改原来的动机页

现有方法的通病

为了稳住内容结构，往往会引入更强的 identity loss、全局残差或保守的重建目标。结果是画面虽然稳定，但风格更像“滤镜覆盖”，很难形成真正的厚涂笔触与局部重绘。

VAE latent 给出的机会

在 32×32 / 16×16 的潜空间里，编码器已经提供了很强的拓扑隐式先验。局部改写不必直接面对像素级几何崩坏，这让“少约束甚至零约束”的风格重构成为可能。

论文最终的主线

与其不断加内容回拉项，不如让 attention backbone 负责长程语义重组，让局部风格调制与微观 SWD 去承担真正的风格能量注入。

一句话版本

- 这项工作的关键不是“把模型做轻”，而是在 VAE 潜空间中找到一种不依赖重内容约束、却仍能稳定重绘的解耦方式。

Latent AdaCUT architecture

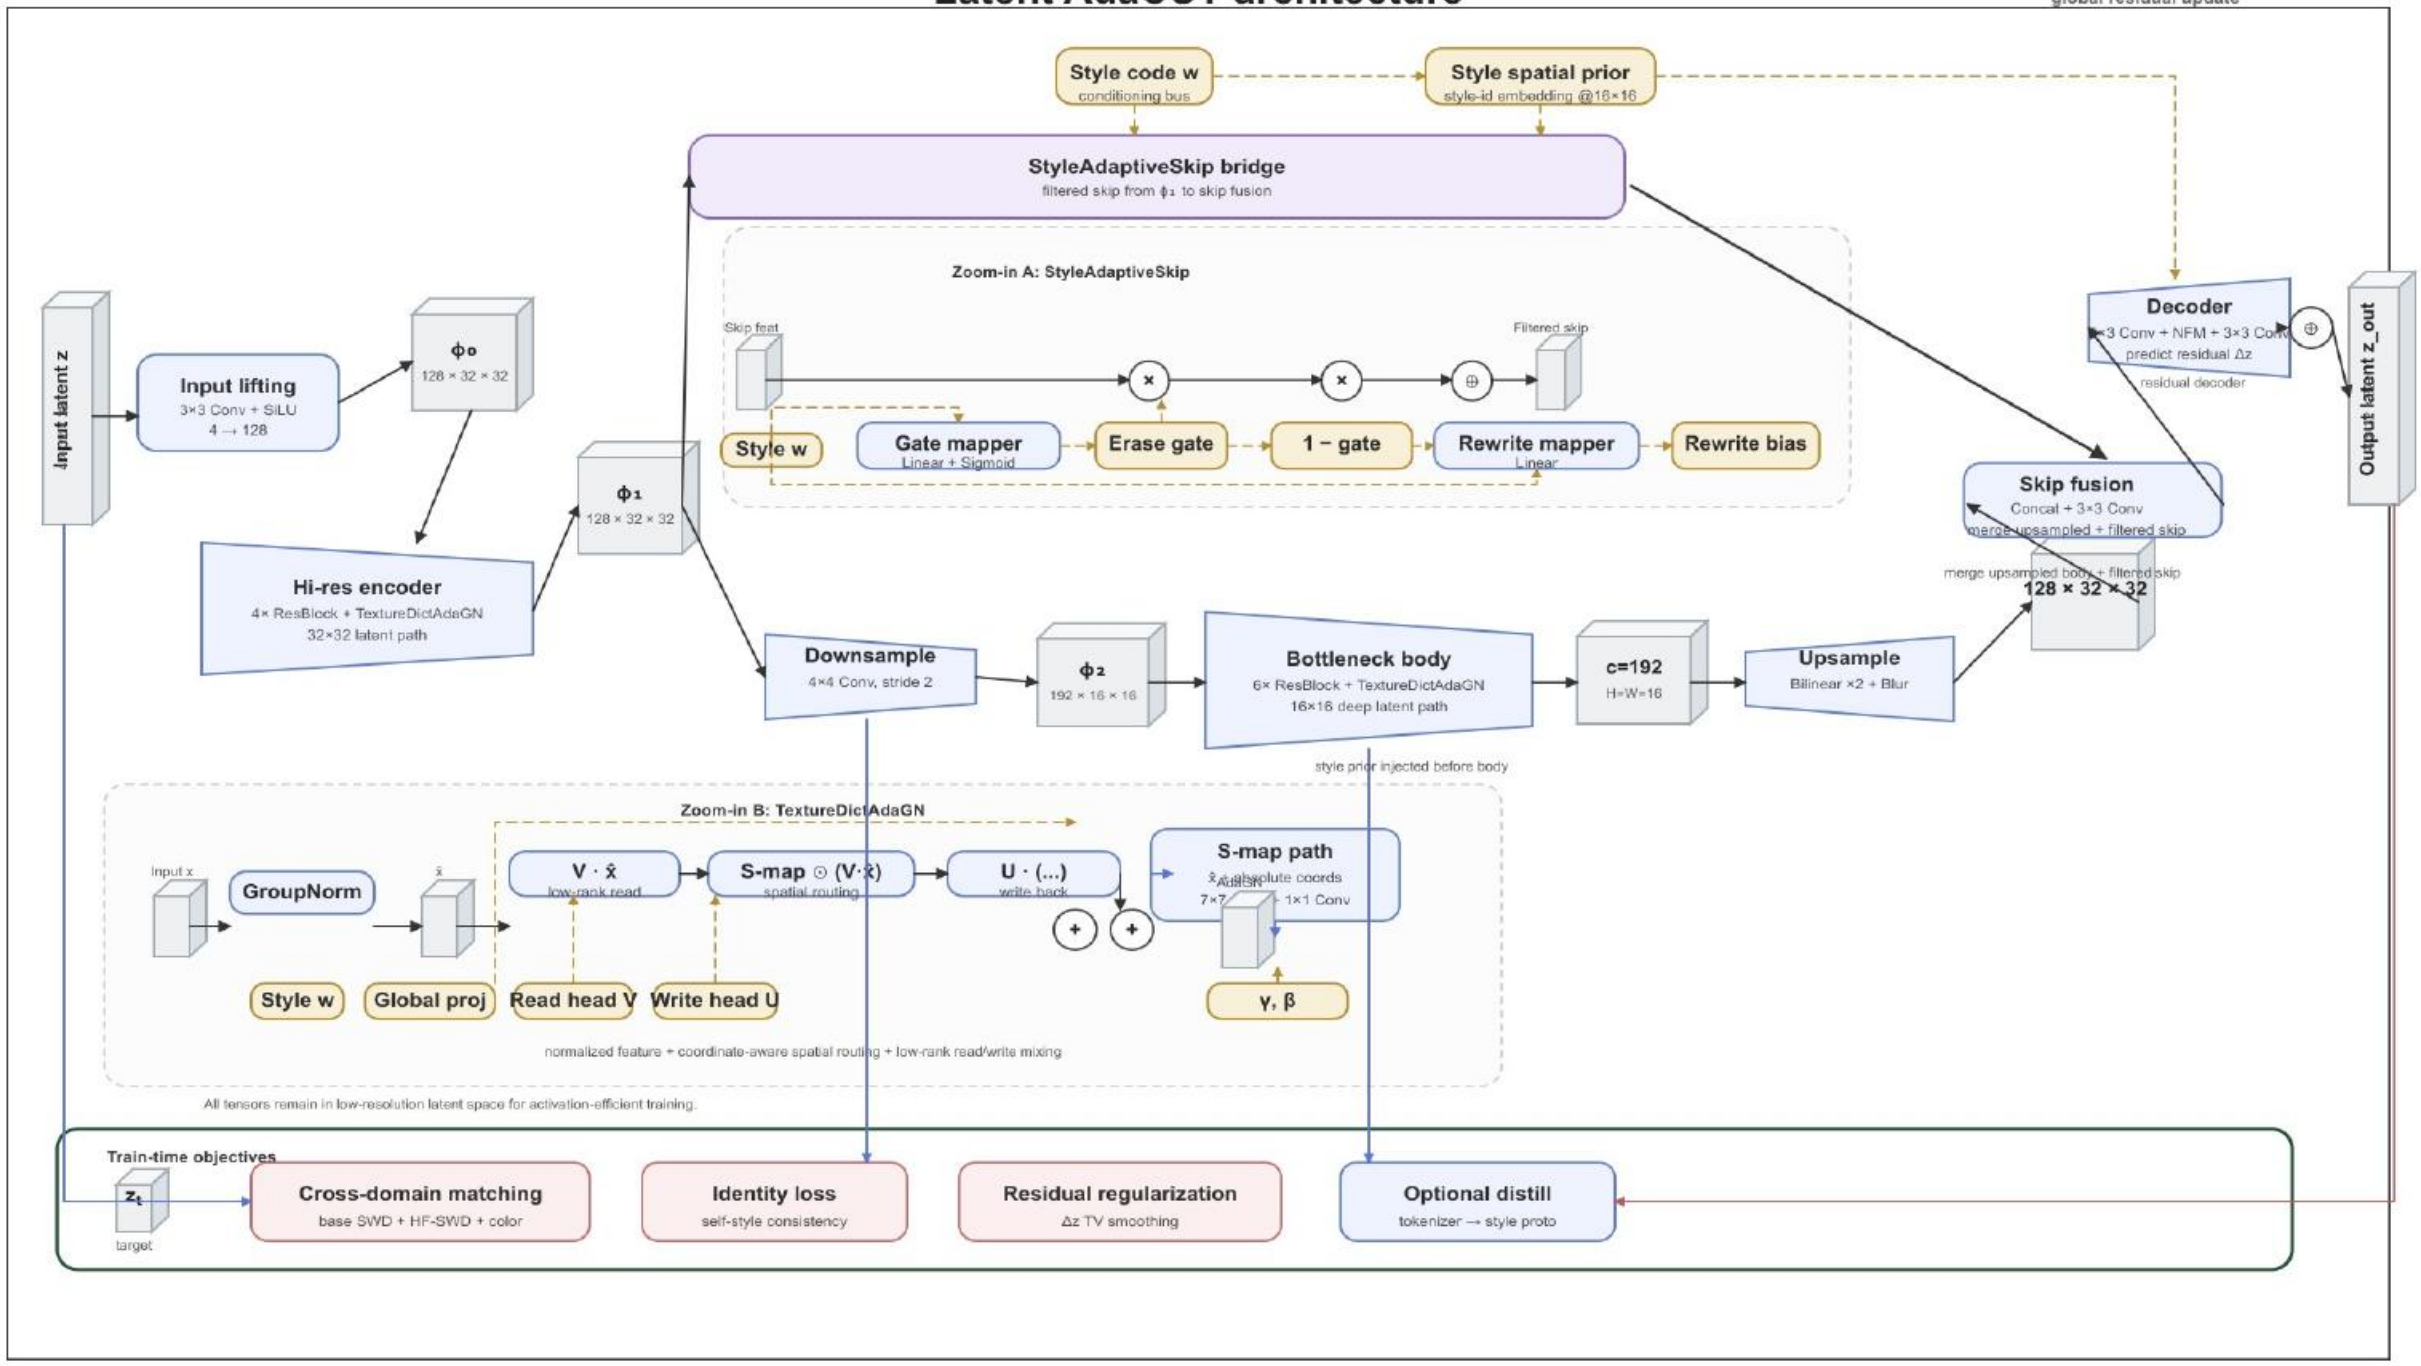

为什么要用SWD（切片Wasserstein距离，推土机距离）

MSE之类的距离衡量，会锁死像素，让模型在惩罚下不敢做出改变；

SWD 最初是作为 FID 的高效替代方案，用于衡量两组图像分布的相似度。它比较的是 集合（生成图所有 Patch 的特征集合 vs 目标风格的所有 Patch 特征集合），它不在乎纹理具体出现在哪个坐标，只在乎生成的纹理分布是否符合整体的统计分布。这允许了模型进行几何变形的同时，将准注入纹理。

通过将最优传输（OT）问题降维至一维投影，我们将复杂的全局优化分解为简单的向量排序问题。

像素空间上为什么没人在训练中使用SWD

标准 SWD 需要对 (N_samples, Projections) 进行全量排序。在 $O(N \log N)$ 的复杂度下，作为评估指标尚可，但直接放入 Loss 函数中，会让训练速度不可接受。（N为样本数，8倍下采样后相当于像素空间的1/64，计算成本可接受）

传统的排序操作虽然是不可导的，但可以通过 **梯度直通 (Straight-Through Estimator, STE)** 实现。然而，单纯的 STE 会导致严重的梯度方差，模型不仅训练极慢，还容易在极值点震荡。

我们的优化

LUT缓存：在训练前对其进行预计算并缓存其排序分布。在训练过程中，模型仅需对当前生成图像的特征执行单次排序，并直接通过 index_select 操作查表获取目标分布的对应值。减少约一半开销

引入 Soft-CDF 逼近算子，利用 Sigmoid 函数替代硬排序的阶梯函数，将离散的排序操作转化为连续的可导映射。这不仅消除了梯度在极值点处的震荡，更实现了对纹理特征流形的连续、平滑引导。

$$\mathcal{L}_{SWD} = \sum_{j=1}^{S} \left\| \mathrm{Sort}\left(\mathrm{Proj}_{\theta_j}(P_{gen})\right) - \mathrm{Sort}\left(\mathrm{Proj}_{\theta_j}(P_{style})\right) \right\|_2^2$$

$$CDF(g) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{I}(x_i \leq g)$$

$$\mathcal{L}_{Soft-SWD} = \sum_{j=1}^{S} \int_{\mathbb{R}} \left| \hat{\mathrm{CDF}}_{gen,\theta_j}(g) - \hat{\mathrm{CDF}}_{style,\theta_j}(g) \right|^2 dg$$

和论文方法部分对齐：最终模型不是“普通卷积器”，而是分工明确的主干

对应论文 3.3–3.8：attention backbone、局部风格调制、微观 SWD

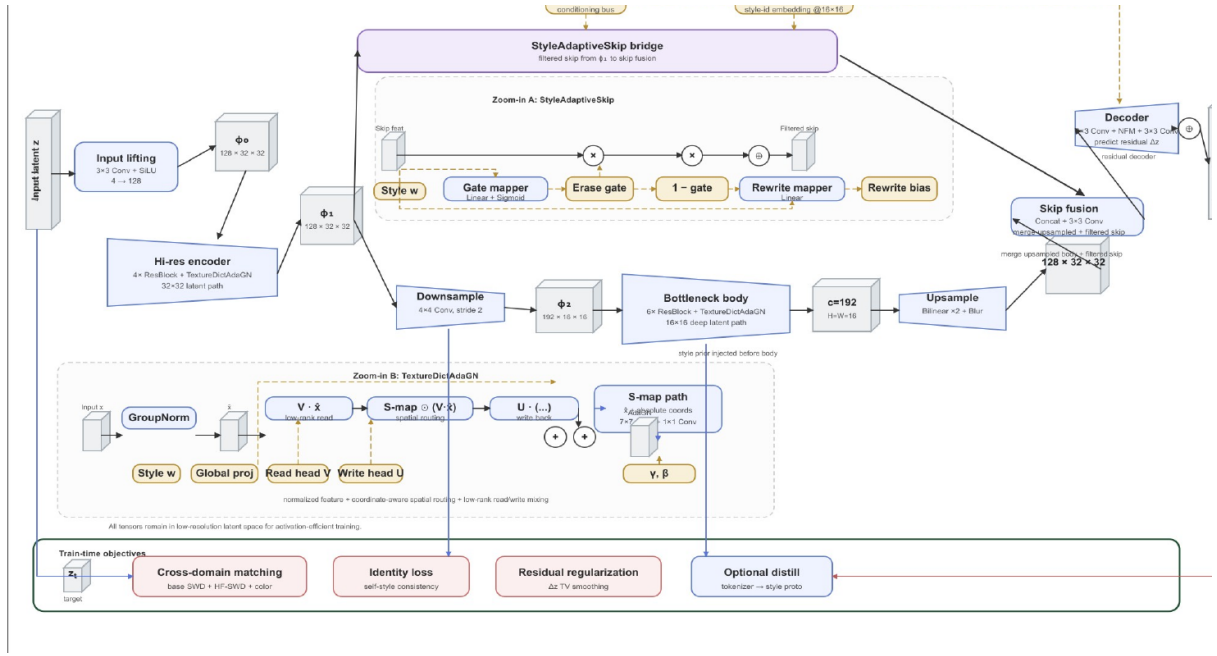

1) Attention backbone：先做长程语义混合

在 32×32 trunk、16×16 body 与 decoder block 中建立 token 间的远距依赖；卷积主要负责 lifting、下/上采样与边界稳定。

2) Style modulator：再把风格能量落到空间位置

CrossAttnAdaGN / TextureDictAdaGN 负责风格到内容的条件注入；skip routing 只保留必要的低频语义，而不是走全局捷径。

3) Objective：风格发生在微观频段

最终真正有效的是 [1,3,5] 微观 patch SWD + 高频 SWD + color 约束，而不是靠更强的 identity 去把输出往回拉。

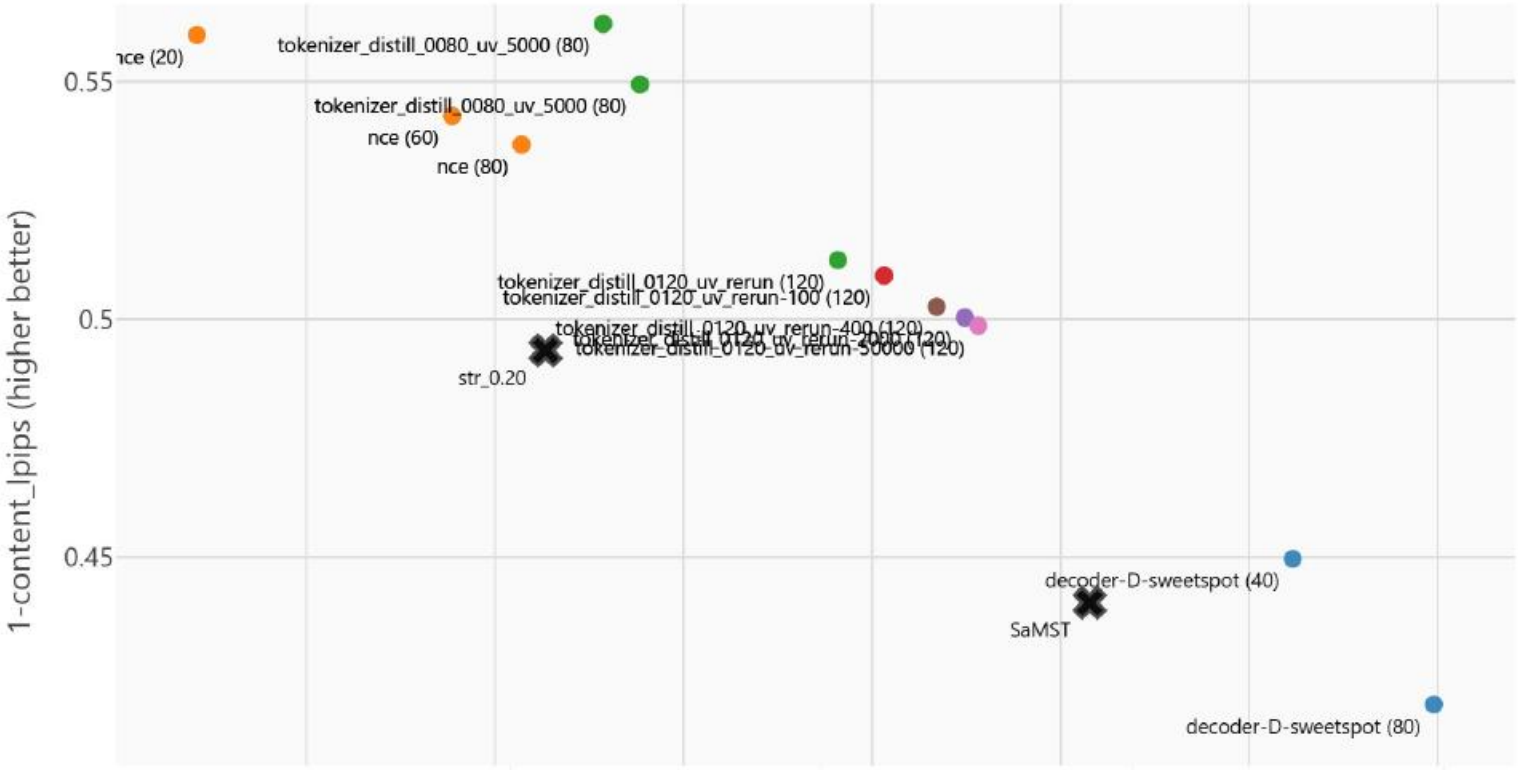

在 clip_style – 1-content_lpips 图上

性能明显优于 sdedit，略优于 SaMST
(ACCV2024)

冻结主干只调整 style_emb
也能让模型进步
且相同 clip 进步下 lpips 损失更小

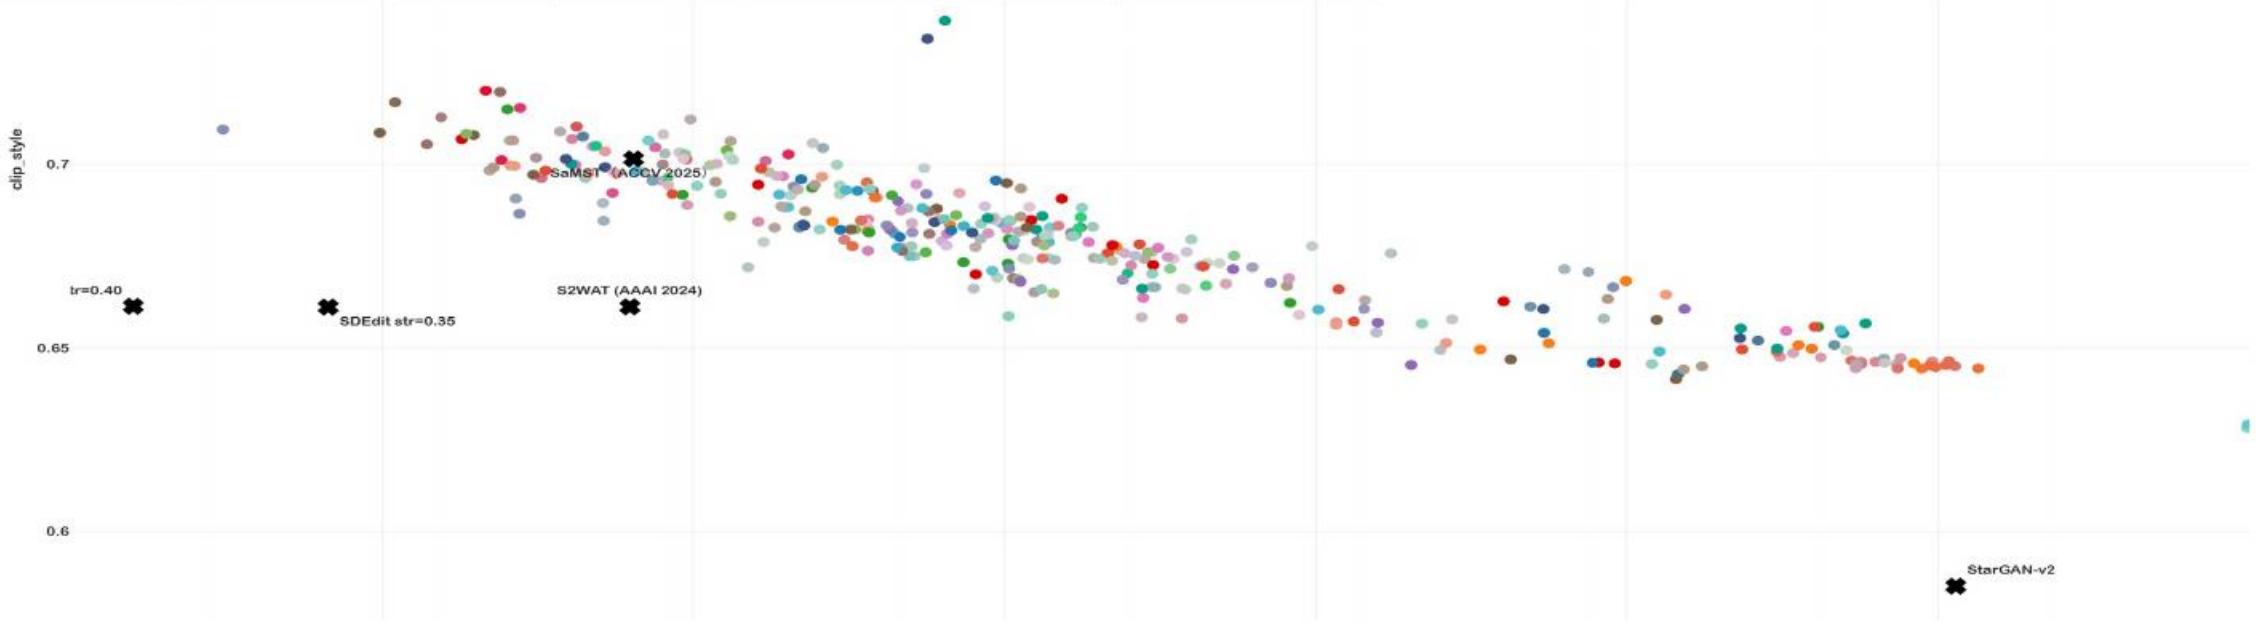

这张散点图到底说明了什么

把现有图和论文结论接起来：不是谁的单项分数高，谁就真的更好

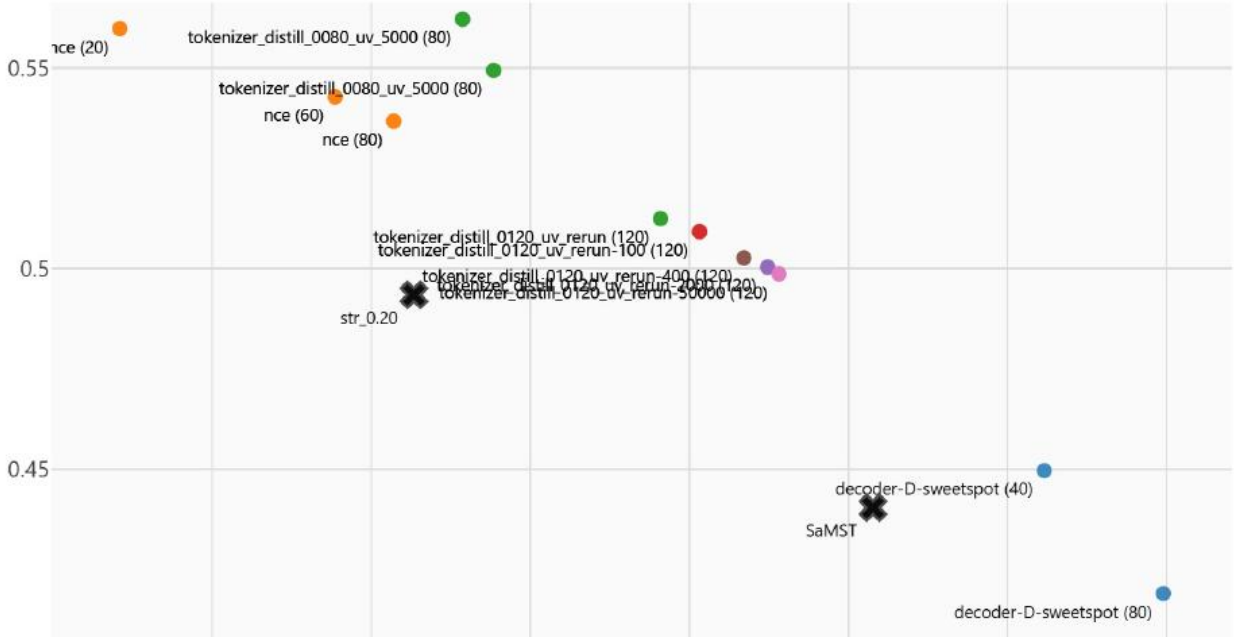

图上的关键信息

- 左上方向代表更强的风格相似度，同时伴随更低的内容形变代价。Ours 明显优于 SDEdit，并与 SaMST 形成可直接比较。
- 冻结主干只调 style_emb 仍能继续上移，说明 backbone 与风格表征已经基本解耦，few-shot 扩展不是“碰巧有效”。

和论文 4.2 的对应关系

- FinalAblation 说明：某些配置可以把 CLIP Style 做高，但会同时推高 LPIPS，视觉上更接近滤镜化或拓扑撕裂。
- 因此我们关心的是 Pareto 前沿，而不是单一指标最高点。真正稳定的 sweet spot 是 attention backbone + 局部调制 + 微观 SWD。

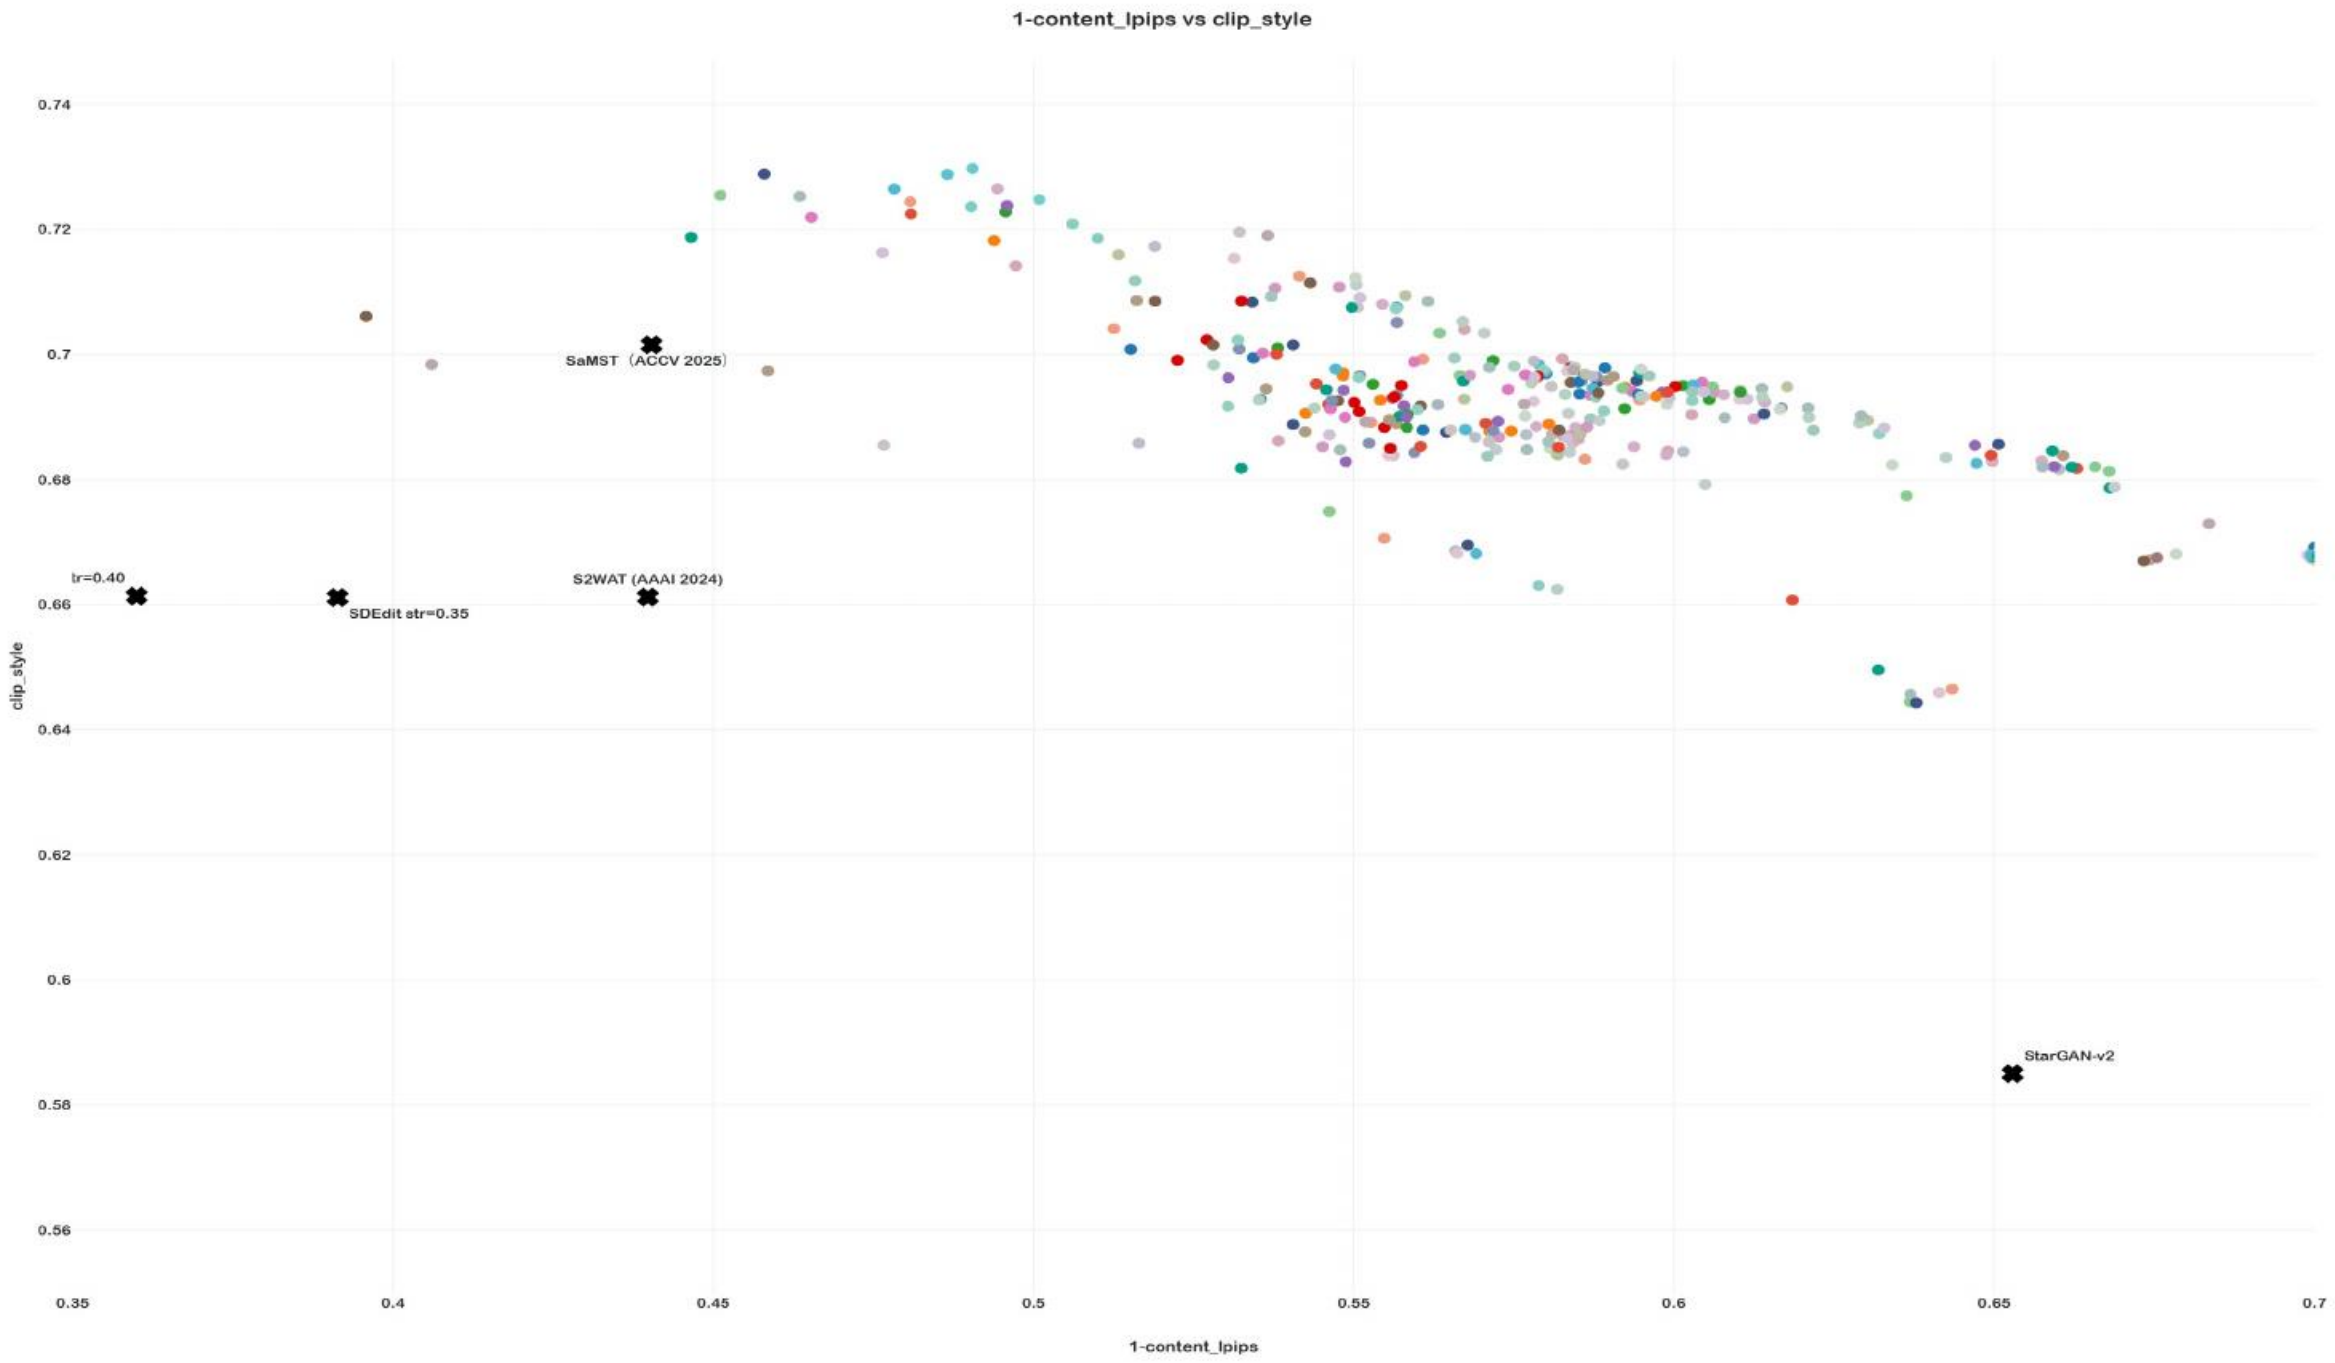
1-content_lpips vs clip_style
0.74
0.72
0.7
0.68
0.66
0.64
0.62
0.6
0.58
0.56
clip_style
0.35
0.4
0.45
0.5
0.55
0.6
0.65
0.7
1-content_lpips
SaMST（ACCV 2025）
tr=0.40
SDEdit str=0.35
S2WAT (AAAI 2024)
StarGAN-v2

配置	Epoch 40 (Mid-Training)			Epoch 80 (Late-Training)		
指标	**CLIP Style ↑**	**CLIP**	**Content**	**CLIP Style**	**CLIP**	**Content**
Baseline	0.687	0.726	0.517	**0.705**	0.702	0.556
结构消融						
w/o Global	0.628*	**0.904***	**0.298***	0.699	0.646	0.613
w/o Adaptive Skip	0.686	0.713	0.534	0.699	0.705	0.550
w/o TextureDict	**0.692**	0.734	0.524	**0.705**	0.711	0.547
Macro Decoder	0.685	0.730	0.520	0.701	0.715	0.542
Dictionary Rank (R)						
R = 1	0.678	0.727	0.509	0.697	0.722	**0.536**
R = 8 (Ours)	0.684	0.734	0.515	0.699	**0.723**	0.539
R = 64	0.682	0.733	0.503	0.698	0.704	0.543

***Baseline** 和下表中的 **ours** 使用的是 **Decoder-d-160** 组实验的结果

Method	**Params ↓**	**CLIP Style ↑**	**CLIP Content ↑**	**Content LPIPS ↓**
StarGAN v2-latent	≈ 43M	0.585	**0.867**	**0.347**
SDEdit (str=0.35)	> 860M	0.661	0.615	0.609
SDEdit (str=0.40)	> 860M	0.661	0.594	0.640
SaMST	≈ 30M+	0.702	0.690	0.560
Ours	**≈ 28M**	**0.720**	0.687	0.583

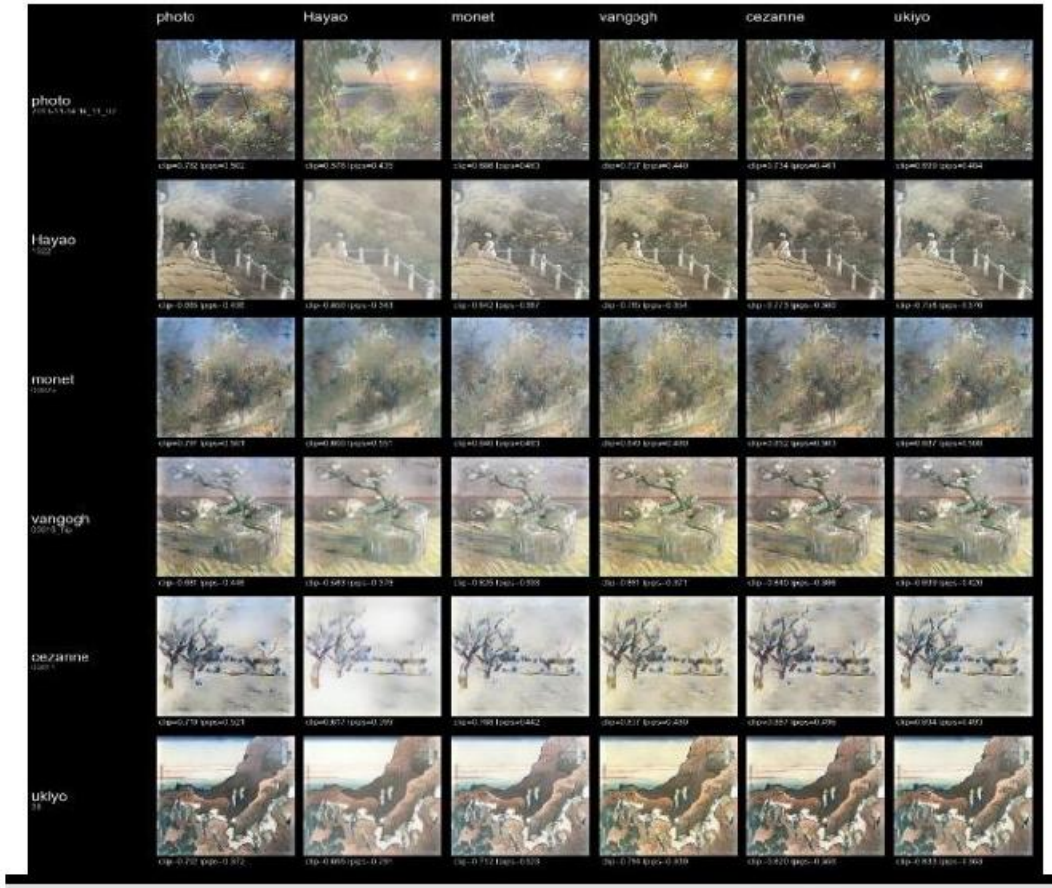

Direction	CLIP Style ↑	Content LPIPS ↓
Old art → ukiyo_e	**0.628238**	**0.324613**
ukiyo_e → Old art	**0.691235**	**0.251996**
photo → ukiyo_e	**0.609058**	**0.329195**
ukiyo_e → photo	**0.672280**	**0.249511**
ukiyo_e → ukiyo_e	**0.868146**	**0.251171**

我们使用富岳三十六景，6 张训练 30 张评估做浮世绘的 few-shot 训练，冻结主干仅训练 style_emb 部分，指标基本无劣化

Setting	5-style Original	6-style Overall	5-style Comparable	Δ Style (6 vs 5)	Δ LPIPS (6 vs 5)
All pairs overview	**0.679523**	**0.678289**	**0.679641**	**-0.001234**	**-0.012595**
Style transfer ability	**0.645539**	**0.649070**	**0.645643**	**+0.003531**	**-0.012705**
Identity reconstruction	**0.815459**	**0.824385**	**0.815632**	**+0.008926**	**-0.012330**
Photo → art performance	**0.611528**	**0.610926**	**0.611393**	**-0.000602**	**-0.000337**

Few-shot 的正确解读口径

把“图上能看见的效果”和论文里的统计结论对应起来

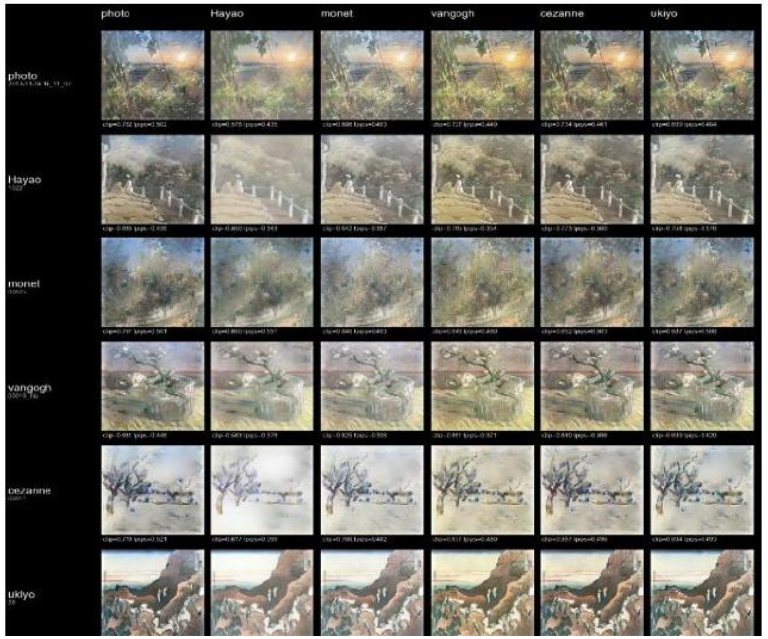

论文里更重要的不是单个例子，而是两层口径

- 5-style comparable：只看原来 5 风格子矩阵时，few-shot 基本没有破坏原模型；说明冻结主干、只调 style_emb 不会显著伤害已学到的风格。
- 6-style overall：把新增 ukiyo_e 一并算进总体后，content LPIPS 从 0.3263 降到 0.3137，style transfer ability 从 0.6455 升到 0.6491，整体是正向收益。

Setting	5-style Original	6-style Overall	5-style Comparable	Δ Style (6 vs 5)	Δ LPIPS (6 vs 5)
All pairs overview	**0.679523**	**0.678289**	**0.679641**	**-0.001234**	**-0.012595**
Style transfer ability	**0.645539**	**0.649070**	**0.645643**	**+0.003531**	**-0.012705**
Identity reconstruction	**0.815459**	**0.824385**	**0.815632**	**+0.008926**	**-0.012330**
Photo → art performance	**0.611528**	**0.610926**	**0.611393**	**-0.000602**	**-0.000337**

Direction	CLIP Style ↑	Content LPIPS ↓
Old art → ukiyo_e	**0.628238**	**0.324613**
ukiyo_e → Old art	**0.691235**	**0.251996**
photo → ukiyo_e	**0.609058**	**0.329195**
ukiyo_e → photo	**0.672280**	**0.249511**
ukiyo_e → ukiyo_e	**0.868146**	**0.251171**

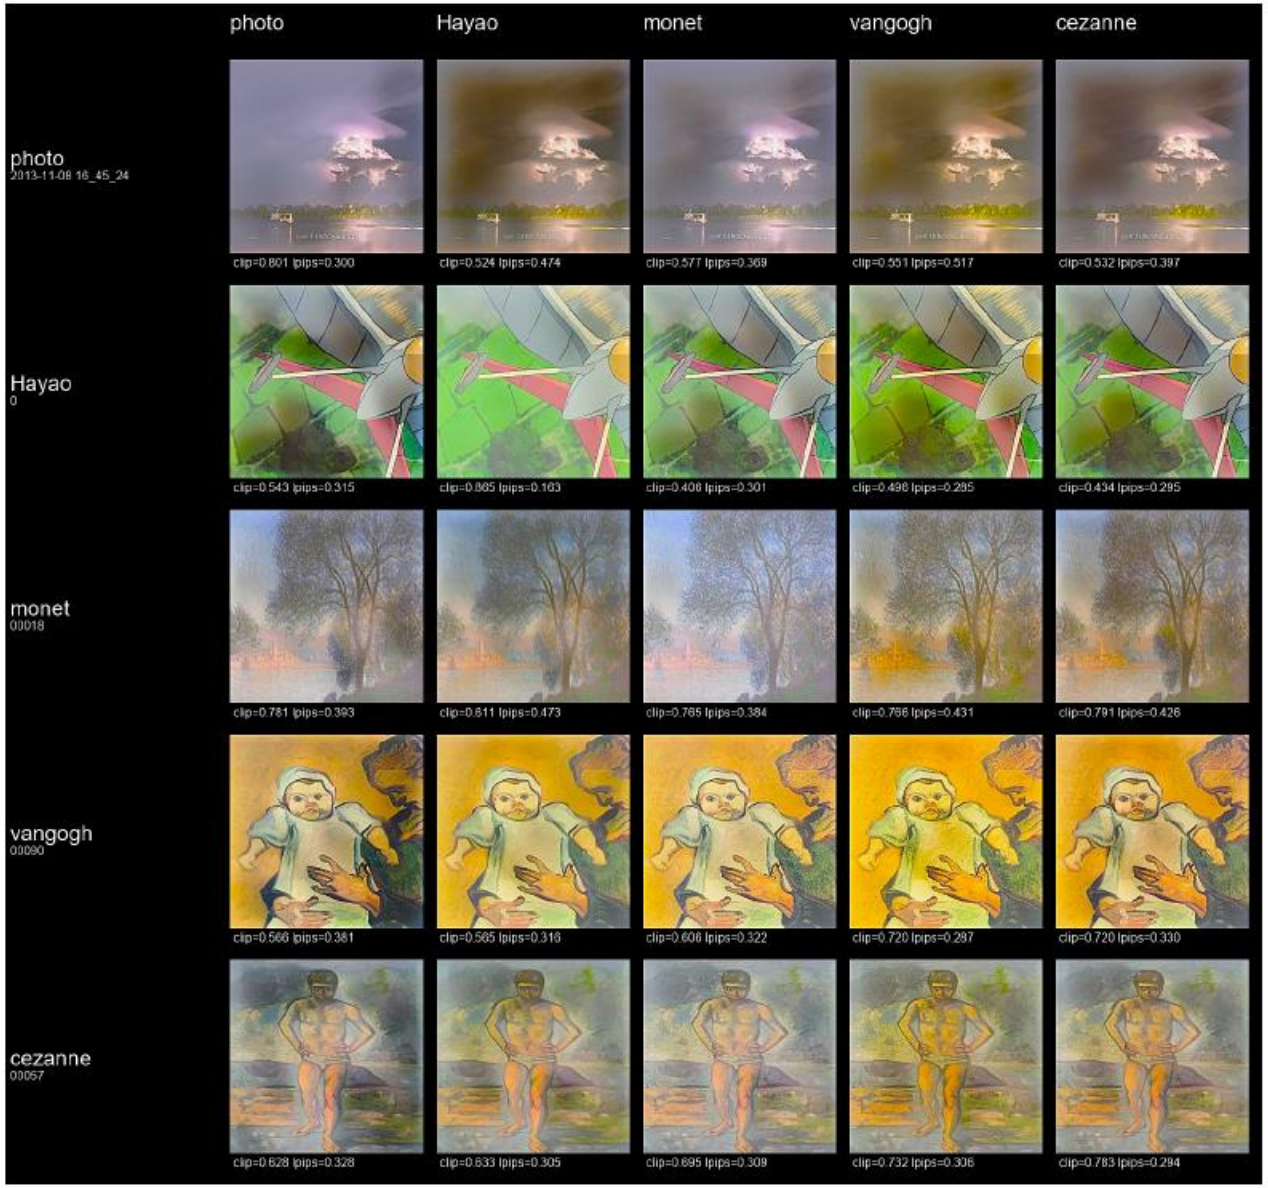

Ours， **KID Delta Ratio** =-13.1%

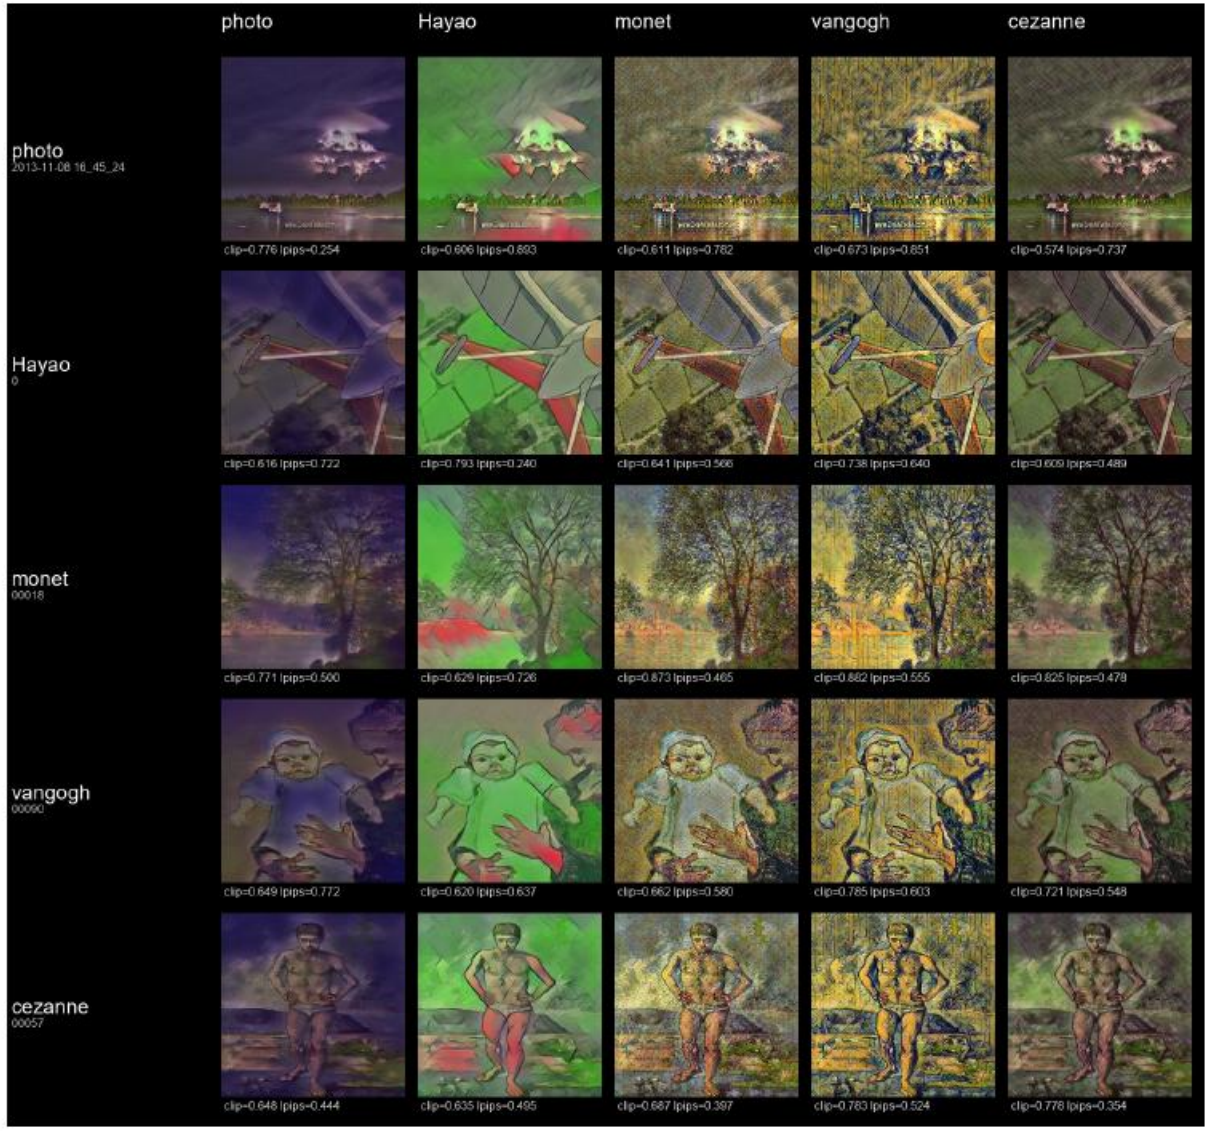

SaMST， **KID Delta Ratio** =-51.2%

为什么 KID 不能单独决定视觉判断

这页补的是“怎么看指标”，不是替换你原来的对比图

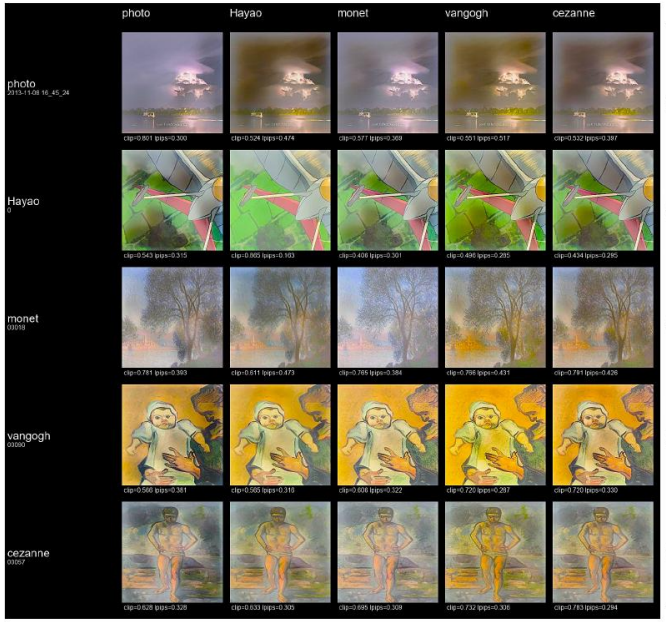

Ours， **KID Delta Ratio** =-13.1%

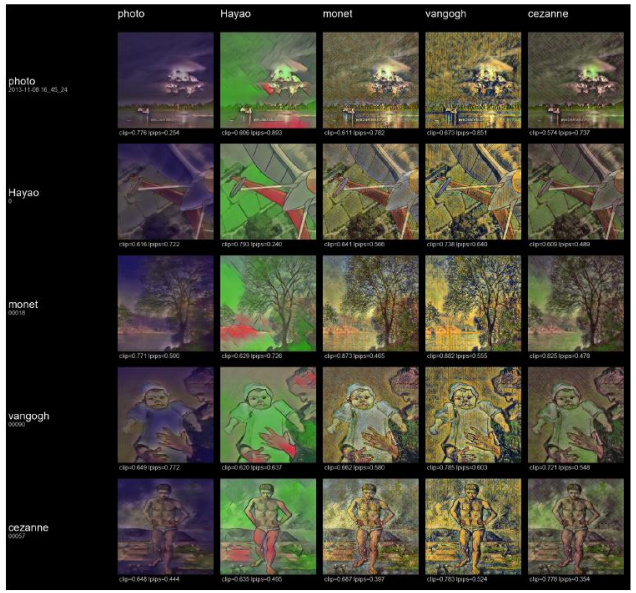

SaMST， **KID Delta Ratio** =-51.2%

这组数字真正说明什么

- Ours 的 KID Delta Ratio 为 -13.1%，SaMST 为 -51.2%。这意味着我们的结果没有沿着“单一分布贴近”去极端优化，而是把更多自由度留给内容保持与可控重绘。
- KID / KID ratio 对全局分布偏差极敏感，但并不直接等价于局部笔触是否自然、纹理是否更像目标风格。

和论文主线的关系

- 论文最后强调的是：在较低 LPIPS 下完成可解释的风格能量注入，比把某个单项统计指标刷到极致更重要。
- 所以这页更适合作为“指标边界”的提醒，而不是单纯的排名页。

- **Photo (基准)**： 保留丰富的高频结构与写实光影。
- **Hayao (宫崎骏)**： 线条明显，呈现柔和的**水彩平涂**与通透色块。
- **Monet (莫奈)**： 边缘柔化，运用**细碎短笔触**营造印象派光影氛围。
- **Van Gogh (梵高)**： 色调转换为标志性暖黄，展现**狂野的螺旋状厚涂笔触**。
- **Cézanne (塞尚)**： 笔触更具**几何结构感**，通过块面堆叠重塑画面。

Method	Params ↓	CLIP-style ↑	CLIP-content ↑	Lpips-content ↓
StarGAN v2-latent	**≈ 43M**	0.585	**0.867**	**0.347**
SDEdit (str=0.35)	> 860M	0.661	0.615	0.609
SDEdit (str=0.40)	> 860M	0.661	0.594	0.640
SaMST	≈ 30M+	**0.702**	0.690	0.560
Ours	**≈ 6M**	0.680	**0.862**	**0.350**
Baseline (decoder-D-160, R=32)		0.687	0.726	0.517
w/o Global Residual		0.628*	**0.904***	**0.298***
w/o Adaptive Skip		0.686	0.713	0.534
w/o TextureDict		**0.692**	0.734	0.524

我们的模型在相近的风格水平下，表现出明显更优的结构保持。
同时，在VAE基础上增加的参数极少，训练/推理开销都相当低
在Latent上的操作未来也可能与Lora之类的模型串行操作，展现出良好的扩展性前景。