基于潜空间的 CycleGAN 风格迁移与分布先验初步研究

摘要：经典的 CycleGAN 模型在无监督风格迁移任务中表现出色，但其通常直接在像素空间运行，面临训练时间长、模型参数量庞大等工程痛点。本研究尝试对 CycleGAN 进行改进，将其训练与推断过程全部迁移至预训练的 VAE 潜空间（Latent Space）中进行。实验结果表明，该方法不仅极大缩减了参数量并提升了训练速度，同时实验现象也暗示，潜空间可能对自然图像分布具有一定的先验知识。

1. 研究背景与动机

CycleGAN 是风格迁移领域中的代表性算法，其核心优势在于不需要成对的图像数据即可学习两种风格（如莫奈画作与现实风景）之间的转换。然而，传统的 CycleGAN 在处理高分辨率像素数据时开销巨大，例如在 RTX 4060 移动端显卡上，使用默认参数完成训练通常需要约 100 小时。此外，其单方向生成器的参数量达到了 11.389M，模型较为臃肿。

本实验的核心思路是放弃**直接处理像素图片，转而将所有的训练数据转换为潜空间数据进行运算。**旨在探索模型在潜空间中进行特征映射的可行性，并通过观察模型的训练表现，初步探讨潜空间本身可能具备的数据分布特性。

2. 核心方法与网络改造

为了让传统的 CycleGAN 在潜空间中稳定运行，本研究首先对原始的损失函数进行了梳理，并针对潜空间向量的数值特性对网络架构和激活函数进行了针对性改造。

2.1 目标损失函数构建

本实验的目标函数沿用了 CycleGAN 的经典设计。以下是涉及到的核心数学符号：

- **X, Y**：代表不同的数据域（例如，X 代表莫奈风格数据集，Y 代表现实风景数据集）。
- **x, y**：分别代表从域 X 和域 Y 中采样的真实潜空间数据样本。
- **G**：生成器，负责将域 X 的特征映射到域 Y（即 X → Y）。
- **F**：生成器，负责将域 Y 的特征映射回域 X（即 Y → X）。
- **Dx, Dy**：判别器，分别负责判断输入的样本是真实的 X/Y 域数据，还是由生成器伪造的数据。
- **λ_cyc, λ_id**：超参数，用于平衡各项损失在总损失中所占的权重。

本实验的风格迁移由以下三个核心损失函数协同优化：

1. 对抗损失

对抗损失的目的是推动生成器输出尽可能接近目标域的真实数据分布。以映射 G: X → Y 为例，对抗损失定义为：

$$L_GAN(G, D_Y, X, Y) = E_\{y\sim p(y)\}[\log D_Y(y)] + E_\{x\sim p(x)\}[\log(1 - D_Y(G(x)))]$$

在此过程中，生成器 G 试图生成逼真的潜空间数据 G(x) 来欺骗判别器，而判别器 D_Y 则力求区分出真实的 y 和生成的 G(x)。反向映射 F: Y → X 亦具有对称的对抗损失。

2. 循环一致性损失

由于缺乏成对数据，仅有对抗损失无法保证输入输出之间的内容对应关系（例如生成器可能将所有的莫奈画作都转换为同一张现实风景图）。循环一致性损失要求样本被转换到目标域后，还能被另一个生成器无损还原，从而约束内容的语义对应。其定义为：

$$L_cyc(G, F) = E_\{x\sim p(x)\}[||F(G(x)) - x||_1] + E_\{y\sim p(y)\}[||G(F(y)) - y||_1]$$

3. 身份损失

身份损失用于进一步约束生成前后的色调和整体结构稳定性。在仅有对抗损失和循环一致性损失的情况下，生成器有时为了迎合判别器，会进行画蛇添足的过度修改（例如白天与黑夜色彩的错误反转）。 身份损失的约束机制是：

当把目标域的真实图片直接输入给负责生成该域的生成器时，生成器应当保持“无作为”，即输出与输入应尽可能保持一致。这有效防止了生成器在输入数据已经具备目标风格时依然强制修改色调。cycleGAN 原版论文中，作者发现这个损失可以有效保持输入输出图像的色彩一致性。其定义为：

$$L_identity(G, F) = E_\{y\sim p_data(y)\}[||G(y) - y||_1] + E_\{x\sim p_data(x)\}[||F(x) - x||_1]$$

4. 总损失函数

综合以上各项，模型最终优化的总损失函数为：

$$L(G, F, D_X, D_Y) = L_GAN(G, D_Y, X, Y) + L_GAN(F, D_X, Y, X) + \lambda_cyc * L_cyc(G, F) + \lambda_cyc * \lambda_id * L_identity(G, F)$$

对抗训练本质上是生成器与判别器之间的持续博弈，因此不同损失项的权重需要进行细致调节以保证训练稳定。

2.2 潜空间特性的适配与架构调整

直接将潜空间数据输入原版网络并不能获得理想效果。针对潜空间向量的相关特性，本实验进行了以下工程改造：

1. 激活函数与数值缩放调整

- **操作**：将生成器最后一层的 `tanh` 激活函数删去，且不再进行线性缩放。
- **原因分析**：原版 CycleGAN 在像素空间操作时，图像通常被归一化到 [-1, 1]，使用 `tanh` 可以很好地限制输出范围，便于还原为像素图片。但在 VAE 潜空间中，目标特征变量是以零为中心、近似高斯分布且无严格固定上下界的连续表示。实验发现，如果强行引入缩放系数并使用 `tanh`，当缩放系数过大会压缩中心高概率区域，整体减小梯度；而在缩放的同时引入 tanh 函数，会导致较大幅值的分量进入 `tanh` 的饱和区，引发梯度消失或数值溢出，解码后图像上会出现明显的白斑。实验证明，直接输出线性结果更为合理。

2. 架构轻量化

- **减小卷积核尺寸**：潜空间数据相较于像素图片，其空间分辨率（特征图尺寸）显著变小。实验通过减小卷积核尺寸来合理调整感受野，这同时也大幅减少了模型参数量。
- **采用残差结构（ResNet Block)**：生成器内部采用残差结构，使得模型不再需要从头生成完整的潜空间向量，而是专注于预测输入数据与目标风格之间的“变化量”（Residuals），从而有效降低了模型的拟合难度与压力。

3. 潜空间先验假设的初步探讨

3.1 异常现象与初步猜想

在早期的代码调试阶段，由于数据集加载逻辑的失误，导致真实风景（photo）数据集被截断，大小被限制到与较小的莫奈（monet）数据集一致。由于 monet 数据集在训练中被反复加载，导致判别器 D_A（负责辨别莫奈风格）发生过拟合，理论上这会导致模型训练崩溃。

然而，实验观察到一个反常现象：在这种不理想的训练条件下，monet2photo（莫奈转真实）的生成效果依然非常出色，仅仅是 photo2monet（真实转莫奈）的效果发生了劣化。

基于此现象，本实验提出一个初步推测：**实验使用的 Stable Diffusion 1.5 VAE 是在海量真实世界图片上进行训练的，其潜空间的分布特征可能对“真实自然图片（Photo）”具有一定程度的先验知识。** 这可能使得潜空间本身的流形（Manifold）就更容易拟合自然图像的分布规律。

3.2 损失曲线的侧面观察

为了寻找支持上述推测的线索，实验提取了训练过程中的对抗损失曲线进行观察。 定义 A 域为 monet，B 域为 photo。观察发现，在训练后期，判别器损失 D_B（判别生成 photo 真实度的损失）的数值往往比 D_A 更加接近理想的博弈均衡点 0.25。这从数学优化的角度暗示了，预训练的 latent 空间与自然图像的分布可能确实更为契合。因此，在数据受限的情况下，模型向现实风格映射（monet2photo）的优化难度似乎天然低于向艺术风格映射（photo2monet）。

3.3 数据规模消融实验

为进一步探讨这一现象，实验设计了不同 photo 数据集大小的对比消融实验。 结果显示：当 photo 数据量极小时，生成的图片出现明显模糊。但有趣的是，当 photo 图片数量仅仅达到 monet 图片数量一半的时候，模型就已经能够输出视觉效果良好的转换结果。这表明，在这种可能的分布先验加持下，模型对目标域（真实世界）数据量的依赖程度似乎有所降低。当然，要确凿地证明这一点，还需要未来更严谨的理论推导与更大规模的实验论证。

4. 实验结果与分析

4.1 工程优势分析

在 VAE 潜空间中运行的 CycleGAN 展现出了显著的工程效率：

- **训练速度极大提升**：在包含约 7k 张图片的 `monet2photo` 任务上，使用 RTX 4060 笔记本可达到约 25s/kimg 的训练速度。整个训练周期大幅缩短，相较于原版动辄上百小时的时间成本，效率有了质的飞跃。
- **极轻量化的模型体积**：经过感受野调整的单方向生成器参数量仅为 1.272M，相较于原版 CycleGAN 单向 11.389M 的参数量，模型体积压缩至原先的约十分之一，而在感官上依旧保持了优秀的风格转换质量。

4.2 模型生成效果展示与说明

模型在双向映射任务中均展现了较好的视觉转化能力。以下为潜空间生成图像的具体解码示例：

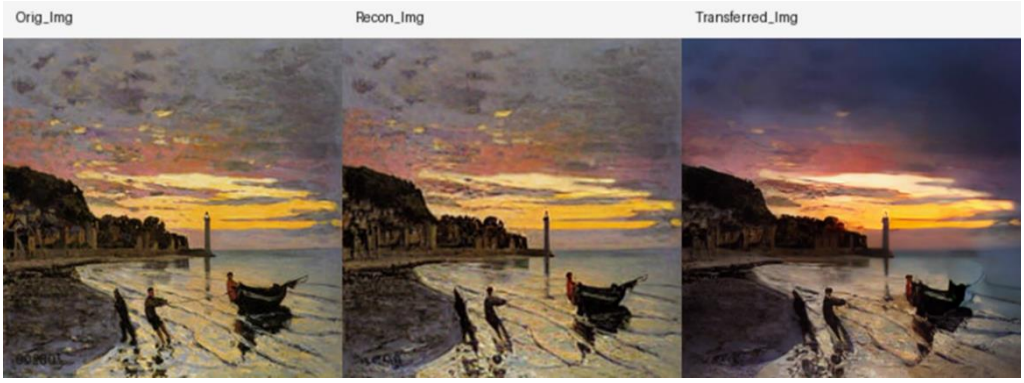

图 1: 莫奈风格向真实风格转换示例

1. 莫奈风格转真实风格 (Monet to Photo)：从图 1 可以观察到，模型成功抹去了莫奈画作中特有的浓厚油画笔触感（Brushstrokes）。在保持原画基本语义结构（如海岸线轮廓、船只位置、灯塔）不被破坏的基础上，模型有效地恢复了水面的物理反射质感（Reflection）以及天空云层的平滑过渡效果。画面整体的色彩饱和度被自适应地调整到了更符合现实光学规律的区间，使得最终输出在视觉上极其接近自然环境下的真实摄影照片。

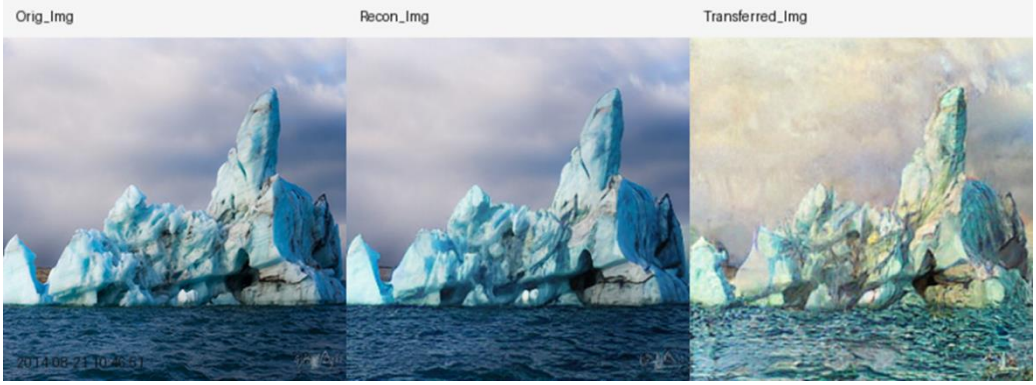

图 2: 真实风格向莫奈风格转换示例

2. 真实风格转莫奈风格 (Photo to Monet)：如图 2 所示，在将现实照片转化为艺术作品时，模型精准地捕捉到了印象派的风格特征。照片中原本锐利、分明的边缘（如冰山锋利的边角、鸭子的轮廓）被艺术化地模糊并重构为带有方向性的笔触。同时，模型对画面的色彩分布进行了重映射，赋予了原本单调的天空和水面以莫奈标志性的柔和且丰富的冷暖色调对冲（Pastel and vibrant hues），呈现出了强烈的印象派油画质感。

4.3 内容-风格帕累托前沿图 (Pareto Frontier) 分析

为了定量化评估模型在“保留原图内容”与“贴近目标风格”之间的权衡能力，实验绘制了内容-风格帕累托前沿图：

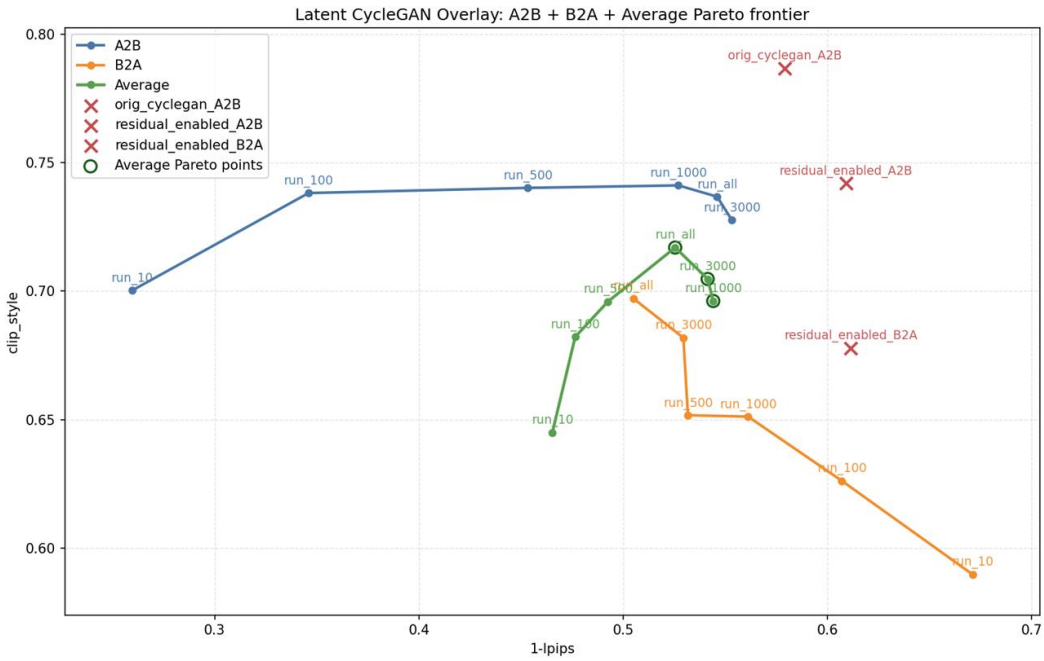

图 3: Latent CycleGAN 内容-风格帕累托前沿分析图

图表中各元素含义如下：

- **坐标轴**：横轴 `1-lpips` 代表内容保留度，数值越高表明生成图像与原图的底层结构差异越小；纵轴 `clip_style` 代表风格迁移强度，数值越高说明生成结果在特征层面上越贴近目标风格。
- **实线轨迹 (A2B, B2A, Average)**：
  - **蓝色实线 (A2B)**：代表莫奈到真实照片（Monet to Photo）在不同数据切片/训练轮次下的表现轨迹。可以看出蓝线整体高居图表左上方，说明其非常容易获得极高的风格得分。
  - **橙色实线 (B2A)**：代表真实照片到莫奈（Photo to Monet）的轨迹。橙线明显偏向图表的右下方，说明模型在处理现实转艺术时，倾向于保留更多的照片内容细节，但风格化程度受到了限制。
  - **绿色实线 (Average)**：代表双向转换的平均水平，直观展现了整体模型的帕累托权衡趋势。
- **散点符号 (X 与 O)**：图中绿色的圆圈（O）标示了平均帕累托最优的参考点。图中的叉号（X）则代表了特定对照组的跑分结果：
  - 顶部独立的叉号（`orig_cyclegan_A2B`）：这是原版像素空间 CycleGAN 的基准成绩，作为参考对比。

- 右侧的红色叉号（residual_enabled_A2B 与 residual_enabled_B2A）：代表本实验中**应用残差结构（Residual Block）之后**的模型表现。可以看出，启用残差结构后，模型在横轴（内容保留度）上获得了显著提升，证明残差结构确实有效帮助模型“记住了”原有特征，让生成器只需关注风格上的变化量。

分析结论：跑分图进一步用定量数据验证了前文的先验假设——由于 VAE 潜空间自身携带强烈的自然图像先验，使得网络“顺势而为”地向现实风格映射（A2B，蓝线）变得十分容易；而如果要逆向打破这种自然规律，强行生成带有笔触的艺术风格（B2A，橙线），其难度则明显增大。这一图表为潜空间流形分布不对称性的猜想提供了有力的数据支撑。

4.4 局限性与未来展望

尽管潜空间实验取得了初步成功，但模型本身仍存在一定局限：

- **对抗训练的不稳定性**：CycleGAN 本质上依然依赖生成器与判别器之间的博弈优化，正如本实验所经历的，不同损失项之间的权重需要经过极为精细的调整（Careful Tuning），否则训练过程极易出现震荡与失衡。
- **扩展性受限**：CycleGAN 的框架仅适用于两个特定域之间的一对一映射。如果需要实现多种不同艺术风格的转换，就需要针对每一对风格重新进行多次独立的训练。

未来工作计划： 针对当前只能进行两种风格转换的痛点，未来的科研尝试计划引入 StarGAN 架构。旨在探索能否在上述潜空间特性的基础之上，使用单一生成器学习并实现五种及以上不同风格之间的灵活转换。