

潜在桥匹配：面向域级艺术风格迁移的高效 OT 耦合流匹配方法

Anonymous submission

Abstract

本文针对艺术风格迁移中风格强度、内容保持和计算成本三个实际约束条件，提出了一种名为潜在桥匹配 (Latent Bridge Matching, LBM) 的高效潜在空间框架。该框架融合了小批量最优传输 (OT) 耦合、时间条件流匹配、语义路由和终端切片 Wasserstein 正则化。OT 耦合为无配对监督提供可信的风格域终点，流匹配学习通向终点的稳定潜在传输路径，终端 SWD 将积分终点与目标域的块统计量对齐。在五个域的严格 750 输出协议下，参数量仅 3.9M 的模型在 CLIP 风格得分上与最强的有效基线 SaMST 几乎持平 (0.716 vs. 0.719)，在 LPIPS 和 EC 上有所提升，训练成本降低约 21.8 $\times$ ，同时在核心迁移指标上也优于更重的 S2WAT 基线。这些结果使 LBM 在域级艺术迁移的效率-质量 Pareto 前沿上占据有利位置。

引言

神经风格迁移长期作为分离图像内容与视觉外观的测试平台。经典神经风格迁移表明，卷积特征和 Gram 统计量可以合成引人入胜的艺术纹理 (Gatys, Ecker, and Bethge 2016)，而前馈任意风格迁移通过基于归一化的风格调制使实时部署成为可能 (Huang and Belongie 2017)。近年来，基于注意力、Transformer、无需训练和基于扩散的系统在灵活性和风格保真度上不断改进 (Park and Lee 2019; Deng et al. 2022; Hong et al. 2023; Huang et al. 2024; Gim, Yoo, and Uh 2024; Chung, Hyun, and Heo 2024)。然而，实用化的多风格艺术迁移仍暴露出一个持久的三方矛盾：强目标风格表达、内容保真度和低计算成本。

这种矛盾在域级多风格迁移中尤为突出。高效多风格系统可以支持多种风格和快速推理，但输出可能变得平淡、过度平滑或被结构性颗粒伪影污染。基于扩散或无需训练的方法可以产生强风格语义，但可能成本高昂或在内容保持评估下出现语义漂移。在严格的 750 输出协议下，StyleID 获得最高的原始 CLIP 风格得分，但表现出严重的结构崩溃，而 SaMST 获得强原始风格和内容得分，却产生可见的泥状和颗粒状纹理伪影。这些观察表明，单纯的标准风格/内容指标是不够的。一个有竞争力的系统还必须在感知质量和伪影敏感的纹理真实性方面进行评估。特别地，当局部纹理变得泥状或颗粒化时，低频结构指标可能高估感知质量。

我们提出 **潜在桥匹配 (LBM)**，将风格化建模为 OT 耦合的潜在流匹配。该方法不是直接预测 RGB 图像，而是在紧凑的 VAE 潜在空间中运行，集成三个组件：(i)

小批量熵最优传输耦合，通过切片 Wasserstein 代价函数匹配无配对的内容和目标风格潜在向量；(ii) 在随机采样的桥接时间上用流匹配监督训练的时间条件速度场；(iii) 将 Euler 积分终点拉向目标风格分布的终端 SWD 正则化器。可学习风格空间先验和语义交叉注意力提供了高效的域级条件化，无需逐图像优化或扩散采样。

本文贡献如下：

- 一种面向域级艺术迁移的**结构化潜在传输公式**，将无配对监督分解为基于 OT 的终点构建、路径式流学习和终端终点正则化。
- 一种带有语义路由和学习空间风格先验的**轻量级潜在主干**，实现高效的域级迁移，无需逐图像优化、扩散采样或参考特定编码。
- 与**最接近的高效基线 SaMST 相比的强效率-质量结果**：CLIP 风格几乎持平 (0.716 vs. 0.719)，LPIPS 改善 (0.451 vs. 0.466)，EC 提升 (0.393 vs. 0.384)，在可比推理速度下训练成本降低约 22 $\times$ 。
- 在**核心迁移指标上持续优于更重的 S2WAT 基线**：更高的 CLIP 风格、更低的 LPIPS、更高的 EC、16.7 $\times$ 更小的模型——表明效率提升并非以牺牲迁移质量为代价。

相关工作

经典与任意神经风格迁移。 神经风格迁移始于基于特征重建和 Gram 矩阵风格损失的优化方法 (Gatys, Ecker, and Bethge 2016)。AdaIN 后来通过逐通道特征统计量对齐实现了实时任意迁移 (Huang and Belongie 2017)。基于注意力的方法如 SANet 通过风格注意力特征聚合改进了局部风格匹配 (Park and Lee 2019)。最近的审美和模式感知方法，包括 AesPA-Net 和 AesFA，进一步强调模式可重复性、审美特征和高保真任意风格迁移 (Hong et al. 2023; Huang et al. 2024)。这些方法展示了特征统计量和局部匹配的价值，但它们通常不对带有终端分布约束的风格条件传输路径进行显式建模。

Transformer 与多风格迁移。 基于 Transformer 的风格迁移方法如 StyTr2 和 S2WAT 利用注意力机制改进内容-风格交互和长距离特征建模 (Deng et al. 2022; Xia et al. 2024)。多风格方法将多种风格摊销到一个紧凑系统中；SaMST 是近期代表性方法，具有可插拔风格表示、低参数量和快速推理能力 (Liu et al. 2024)。这些系统与我们的**高效多风格迁移目标**直接相关。在实验

中, SaMST 作为最接近的高效基线, 而 S2WAT 作为最相关的重型模型参考。与仅表示的风格注入不同, 我们的方法将语义交叉注意力置于潜在桥目标内部, 因此终端分布匹配和运动正则化显式地塑造了风格-内容权衡。

无需训练和扩散方法。 无需训练和基于扩散的方法为灵活的风格迁移提供了不同路径。CAST 使用 VQ 自编码器进行内容自适应的无需训练风格迁移 (Gim, Yoo, and Uh 2024), 而 StyleID 无需训练即可将风格注入大规模扩散模型 (Chung, Hyun, and Heo 2024)。这些方法在视觉上可能很强, 但扩散采样和语义漂移可能限制其对快速域级迁移的适用性。我们的工作针对互补的效率 regime: 使用风格 id 条件的紧凑潜在集成, 而非迭代扩散采样或逐风格优化。

分布匹配与感知评估。 我们的目标受最优传输和分布匹配的启发。Sinkhorn 距离和计算最优传输为近似传输问题提供了高效工具 (Cuturi 2013; Peyré and Cuturi 2019), 而 Schrödinger 问题将熵传输与随机路径测度联系起来 (Léonard 2014)。我们使用 SWD 作为轻量级终端分布匹配目标。我们对 OT 的使用是实践性的而非定理级别的: 它作为潜在空间中的小批量终点构建机制, 而非精确全局传输最优性的声明。对于评估, 我们结合感知和分布测量, 包括 LPIPS (Zhang et al. 2018)、FID (Heusel et al. 2017)、KID (Bińkowski et al. 2018)、DISTS (Ding et al. 2020)、MUSIQ (Ke et al. 2021)、MANIQA (Yang et al. 2022) 和风格迁移专用的 ArtFID (Wright and Ommer 2022)。这个广泛的指标集很重要, 因为原始 CLIP 风格和结构得分可能无法惩罚颗粒状伪影。

方法

概述

LBM 最好被理解为域级艺术迁移的结构化潜在传输设计。我们将其建模为 OT 耦合的潜在流匹配。设 $z_0 \in \mathbb{R}^{4 \times 32 \times 32}$ 为内容图像的 VAE 潜在向量, s 为目标风格域标识符。该方法有三个组件: (i) 最优传输耦合, 在每个小批量内匹配无配对的内容和目标风格潜在向量; (ii) 在随机采样的桥接时间上用流匹配监督训练的时间条件速度场 $v_\theta(z_t, t, s)$; (iii) 将积分终点拉向目标风格分布的终端切片 Wasserstein 正则化器。在推理时, 学习到的向量场通过显式 Euler 步骤积分并由 VAE 解码器解码。

无配对潜在域采样与 OT 耦合

我们直接在预计算的 VAE 潜在向量上训练, 无需配对监督。每个小批量从所有源域采样内容潜在向量 $\{z_c\}$, 从请求的目标域采样目标风格潜在向量 $\{z_s\}$ 。身份对通过均匀目标域采样自然包含, 这稳定了围绕同域映射的学习传输。

我们不使用随机目标分配, 而是使用切片 Wasserstein 代价构建小批量传输耦合。对于一批内容潜在向量 $\{z_c^{(i)}\}$ 和目标风格潜在向量 $\{z_s^{(j)}\}$, SWD 代价矩阵为

$$C_{ij} = \text{SWD}(z_c^{(i)}, z_s^{(j)}). \quad (1)$$

然后通过 Sinkhorn 算法获得熵最优传输计划:

$$\pi^* = \arg \min_{\pi} \sum_{ij} C_{ij} \pi_{ij} + \epsilon H(\pi), \quad (2)$$

其中 $H(\pi)$ 是熵正则化器。每个内容潜在向量与其耦合的目标 $\tilde{z}_1 \sim \pi^*(z_s | z_c)$ 匹配。此耦合在不需要空间对齐目标的情况下提供风格域终点。

时间条件潜在流匹配

该方法的核心是时间条件速度场 $v_\theta(z_t, t, s)$, 它沿随机桥传输潜在向量。在随机采样的时间 $t \sim \mathcal{U}(0, 1)$, 桥状态为

$$z_t = (1-t)z_0 + t\tilde{z}_1 + \sigma\sqrt{t(1-t)}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I), \quad (3)$$

目标速度是传输的导数:

$$u_t = \tilde{z}_1 - z_0 + \sigma \frac{1-2t}{2\sqrt{t(1-t)}} \epsilon. \quad (4)$$

流匹配目标监督网络预测此速度:

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{z_0, \tilde{z}_1, t, \epsilon} \|v_\theta(z_t, t, s) - u_t\|^2. \quad (5)$$

此公式可以解释为沿随机桥学习去噪类速度场, 并且自然地路径内容保持与终点风格匹配分开。

架构。 时间条件主干使用正弦时间嵌入添加到风格编码中。实现是类似 U-Net 的潜在主干, 在 16×16 分辨率处有四个语义交叉注意力主体块。目标风格由可学习空间先验 $P_s \in \mathbb{R}^{128 \times 16 \times 16}$ 表示。语义交叉注意力将风格先验注入内容特征, 而跳跃连接保留空间结构。

互补角色。 各组件解决不同的子问题。OT 耦合为无配对监督提供目标风格终点, 但不提供传输动态。流匹配学习如何向这些终点移动, 但自身不能保证积分终点匹配目标域纹理统计量。终端 SWD 正则化此终点不匹配, 而语义交叉注意力为写入风格的位置提供局部路由。破坏性消融直接验证了终端 SWD 和运动正则化的作用; 隔离 OT 耦合和语义路由的额外组件研究留待未来工作。

终端 SWD 正则化

除了流匹配监督外, 终端损失将 Euler 积分终点正则化到目标风格分布。设 $\Phi_\theta(z_0, s)$ 为从 z_0 和风格 s 积分 v_θ 得到的终点。终端损失为

$$\mathcal{L}_{\text{term}} = \text{SWD}(\Phi_\theta(z_0, s), \tilde{z}_1), \quad (6)$$

其中 SWD 使用 64 个投影在块大小 $\{3, 5, 7, 15\}$ 上比较生成终点块与耦合目标块。

完整训练目标结合了流匹配、终端分布匹配和运动路径正则化:

$$\mathcal{L} = \mathcal{L}_{\text{FM}} + \lambda_{\text{term}} \mathcal{L}_{\text{term}} + \lambda_{\text{kin}} \mathcal{L}_{\text{kin}}, \quad (7)$$

其中 $\mathcal{L}_{\text{kin}} = \mathbb{E} \|v_\theta\|_2^2$ 惩罚过度潜在位移。主配置使用 $\lambda_{\text{term}} = 20.0$ 和 $\lambda_{\text{kin}} = 1.0$ 。在主设置中禁用颜色、循环、NCE 和排斥损失。这个三部分损失将驱动风格的力与保持内容的力分开。

paragraph 有界的理论声明。该方法不是精确的 Schrödinger 桥求解器。它不估计前向和后向随机得分, 也不优化完整的熵对偶目标。桥视角被用作可处理的训练原则: 流匹配路径约束、终端分布正则化和运动惩罚。这一有界解释在经验上得到反映——移除终端约束削弱风格, 而移除路径惩罚则破坏内容。




Figure 1: 潜在传输模型概览。

更具体地，设 $\mathcal{P}_r(\hat{z}_1)$ 为从生成终点提取的大小为 r 的潜在块集合， $\mathcal{P}_r(z_s)$ 为来自目标风格样本的对应块集合。对于投影方向 $\{\theta_m\}_{m=1}^M$ ，经验终端目标为

$$\mathcal{L}_{\text{swd}} = \sum_{r \in \mathcal{R}} \frac{1}{M} \sum_{m=1}^M \left\| \text{sort}(\mathcal{P}_r(\hat{z}_1)\theta_m) - \text{sort}(\mathcal{P}_r(z_s)\theta_m) \right\|_2^2. \quad (8)$$

其中 $\mathcal{R} = \{3, 5, 7, 15\}$ 为主配置。因此，损失询问生成终点是否具有目标风格块统计量，而非是否在空间上匹配任何特定艺术作品。

实验

协议与指标

我们在严格的 750 输出协议下进行评估：五个源域乘以五个目标域乘以 30 张源图像。五个域为 photo、Hayao、Monet、Van Gogh 和 Cezanne；Ukiyo-e 在当前协议中未使用。我们报告 CLIP 风格、CLIP 内容、LPIPS 内容和复合得分

$$\text{EC} = \text{CLIP} \cdot (1 - \text{LPIPS}). \quad (9)$$

对于伪影敏感分析，我们还报告 MUSIQ、MANIQA、DISTS 内容、高频块 KID、FFT 斜率误差和浅层 Gram 微观统计量。我们在严格 750 协议下对 Ours、SaMST、StyleID、S2WAT 和 AdaIN 变体进行端到端评估。

指标分类。

域级评估的公平性。 所有基线在相同的严格 750 协议下进行评估：每张源图像在编码前调整大小为 256^2 ，所有目标域参考图像遵循相同的预处理，并且每个方法都包含身份方向（相同源域和目标域）。对于任意风格方法（AdaIN、S2WAT、CAST），每批次第一个可用的目标域图像作为风格参考；对于无需训练的扩散方法（StyleID），每个目标域使用单一风格参考。此协议确保指标差异反映方法能力而非评估不对称。

我们使用四个指标组。原始语义指标 CLIP 风格和 CLIP 内容衡量输出是否被识别为与输入风格对齐且语义相关。感知内容指标 LPIPS 和 DISTS 内容衡量视觉结构保持。分布风格指标，包括 KID、Gram 统计量和高频块 KID，评估生成的纹理统计量是否类似于目标风格图像。无参考图像质量指标 MUSIQ 和 MANIQA 帮助检测脏或过度处理的输出。我们仅将 EC 用作内部 Pareto 诊断以进行扫描选择；所有声明都针对单个指标进行检查。

主要对比

关键对比是针对 SaMST 和 S2WAT。最强的有效基线是 SaMST。相对于 SaMST，我们的方法在 CLIP 风格上基本持平（0.716 vs. 0.719），LPIPS 改善（0.451 vs. 0.466）和 EC 提升（0.393 vs. 0.384），参数量从 6.0M 降至 3.9M，在可比推理速度下训练成本降低约 22 $\times$ 。这是核心经验结果：LBM 在保持最强有效基线的质量域的同时大幅降低训练成本。

相对于 S2WAT，LBM 不仅更小、训练更便宜，而且在核心迁移指标上也更强：更高的 CLIP 风格、更低的 LPIPS、更高的 EC。此对比表明效率提升并非以牺牲迁移质量为代价——LBM 明显在此重型基线上处于 Pareto 有利位置。

AdaIN 在推理时保持更快，但明显处于高质量前沿以下（LPIPS 0.630，EC 0.264），而 StyleID 以严重的结构漂移为代价获得最高的原始 CLIP 风格（0.760，LPIPS 0.750，CLIP 内容 0.552）且推理速度慢得多（603 秒/750 张图像）。CAST 在核心指标上也落后。表 1 中还包含了其他基线（StyTr2 48.3M、AesPA-Net 24.2M、AesFA 3.2M）并给出了完整的计时数据。

针对 SaMST 的伪影敏感对比

由于 SaMST 是核心指标下最接近的高效基线，我们将其作为伪影聚焦诊断的主要目标。尽管其标题得分具有竞争力，但放大检查显示标准风格/内容指标无法充分惩罚的泥状和颗粒状局部纹理。CLIP 内容、SSIM 和边缘重叠等指标奖励低频结构保持；因此，如果对象边界保持可见，即使局部纹理在视觉上很脏，颗粒化输出也可以获得高分。

为捕捉此失效模式，我们在表 2 中检查三个最高质量方法（Ours、SaMST、S2WAT）的伪影敏感诊断。相对于 SaMST，Ours 将 MUSIQ 从 36.10 提升至 49.21，MANIQA 从 0.314 提升至 0.406，DISTS 内容从 0.294 降至 0.248，高频块 KID 从 6.76 降至 4.17，FFT 斜率误差从 1.054 降至 0.547。S2WAT 在三者中显示最低的 MANIQA（0.175）和最高的高频块 KID（12.66），表明更明显的纹理伪影。这些提升表明我们的方法虽然在原始风格上略不激进，但在块级别上视觉上更干净——

Table 1: 严格 750 对比与效率。 $\uparrow$ = 越高越好, $\downarrow$ = 越低越好。750 张图像的端到端推理时间。标记 $\dagger$ 的训练时间为外推估计。

方法	参数量	CLIP 风格 $\uparrow$	LPIPS $\downarrow$	EC $\uparrow$	推理 (秒)	毫秒/图	训练秒
Ours ep7	3.9 M	0.716	0.451	0.393	40.0	53	309.9
SaMST	6.0 M	0.719	0.466	0.384	39.8	53	6768.7 $\dagger$
S2WAT	~ 7 M	0.714	0.526	0.338	45.1	60	10600 $\dagger$
AdaIN v32k	~ 5 M	0.713	0.630	0.264	9.3	12	9220.4
StyleID	SD-based	0.760	0.750	0.190	603.3	804	free
CAST	7.0 M	0.665	0.726	0.182	75.5	101	free
StyTr2	48.3 M	0.681	0.589	0.280	567.4	757	143.5
AesPA-Net	24.2 M	0.658	0.712	0.189	345.3	461	366.3
AesFA	3.2 M	0.669	0.701	0.200	40.3	54	6607.6

$\dagger$ 外推。毫秒/图 = 750 输出的端到端推理每图毫秒数。




Figure 2: 严格 750 风格—内容权衡。我们的原始 CLIP 风格接近 SaMST, 同时比多个基线保持更好的 LPIPS 基础权衡; StyleID 达到高风格但崩溃了内容。

与图 3 中的定性网格一致。所有图中的放大裁剪使用跨方法的相同源—目标对的空间匹配位置。

为评估统计可靠性, 我们对 Ours 的 750 张逐图像得分进行配对 bootstrap 检验。95% bootstrap 置信区间 (5000 次重采样) 为: LPIPS [0.4467, 0.4563], CLIP 风格 [0.7091, 0.7234]。按评估方向分离, photo 转艺术子集 ($n = 120$) 产生 CLIP 风格 0.6716 和 LPIPS 0.4882, 而非身份子集 ($n = 600$) 产生 CLIP 风格 0.6911 和 LPIPS 0.4609, 确认主要结果在评估条件间是稳健的。

破坏性消融

表 3 中的消融结果揭示了模型的机制。移除终端 SWD 给予出色的内容保持但弱的风格, 表明终端分布匹配是主要风格驱动力。移除运动正则化保持风格但崩溃内容, 确认路径能量惩罚是必不可少的。强颜色损失损害

Table 2: 高质量方法间的伪影敏感对比。

指标	Ours e7	SaMST	S2WAT
MUSIQ $\uparrow$	49.2059	36.0950	36.5256
MANIQA $\uparrow$	0.4057	0.3139	0.1754
DISTS 内容 $\downarrow$	0.2477	0.2943	0.2942
高频块 KID $\downarrow$	4.1694	6.7598	12.6623
FFT 斜率误差 $\downarrow$	0.5473	1.0536	0.7017
Gram 微观 $\downarrow$	0.0798	0.0947	—

Gram 微观在当前评估协议中未为 S2WAT 重新计算。

Table 3: 严格 750 协议下的破坏性消融。

变体	CLIP 风格	CLIP 内容	LPIPS	EC
D0 完整	0.7014	0.8022	0.4593	0.3791
D1 无终端 SWD	0.6708	0.8989	0.3490	0.4368
D2 无运动	0.7159	0.6624	0.6375	0.2596
D8 强颜色损失	0.6923	0.6629	0.5675	0.2994

内容和分布质量, 因此为主线中不使用朴素颜色匹配。

权重扫描与理论切换

40 轮类别权重扫描以 $K \in \{1, 2\}$ 各训练 20 种采样策略, 每个训练 8 个 epoch, 评估每个 epoch 共 320 个检查点。最佳 EC 结果为 K2 平衡默认第 3 epoch, CLIP 风格 0.6980, CLIP 内容 0.8727, LPIPS 0.3777, EC 0.4343。扫描中最佳原始风格结果为 K1 平衡默认第 8 epoch, CLIP 风格 0.7161, CLIP 内容 0.7984, LPIPS 0.4605, EC 0.3863。扫描表明更复杂的类别权重并不一致地优于平衡采样。

我们还评估了可选的理论切换。Sinkhorn 归一化语义路由和熵门控运动正则化改善 EC/内容但降低原始 CLIP 风格。最佳理论切换 EC 为熵门控运动, 权重 5.0 第 1 epoch, 给予 CLIP 风格 0.6916, CLIP 内容 0.8804,




Figure 3: Ours epoch 7 和 SaMST 严格的定性 5×5 源-目标网格。行表示源域，列表示目标域。SaMST 保留粗粒结构但经常产生泥状、颗粒状表面纹理；我们的方法在原始风格上不那么激进但在视觉上更干净。




Figure 4: 匹配的 Ours 和 SaMST 输出的居中纹理裁剪，隔离表面纹理失效模式。

LPIPS 0.3684, EC 0.4368。颜色传输略微提升原始风格但损害 LPIPS 和内容，因此未被选为主线。

步数与 λ 敏感性

额外的步数扫描评估所选第 7 epoch 检查点的 1、4、8、12 和 16 个 Euler 步骤。主要观察是质量曲线在此范围内几乎平坦。全配对 CLIP 风格得分仅从 0.7159 变化至 0.7162，而 LPIPS 保持紧密集中在 0.4514 左右。Photo 转艺术操作点同样稳定：CLIP 风格仅从 0.6712 变化至 0.6715，LPIPS 保持在 0.4881 附近。这意味着 12 步默认不是脆弱的调优最优值。实际上，四步已经恢复几乎相同的质量，而测量的严格 750 端到端吞吐量从 1 步的 8.43 图像/秒增加到 4 步的 9.54 图像/秒，并在 8—16 步保持在约 9.34—9.50 图像/秒。近似平坦的步曲线表明在所选操作域中学习到向量场是稳定的，而非表明迭代积分不必要。因此我们保持 12 步作为保守




Figure 5: 破坏性消融。移除终端 SWD 改善内容但削弱风格，而移除运动正则化在严重内容退化代价下提升风格。

默认，但扫描表明较低步部署是可行的，当边际延迟减少重要时。

我们还在 $\lambda_{kin} \in \{0.5, 1.0, 2.0\}$ 和 $\lambda_{swd} \in \{10, 20, 30\}$ 上扫描 3×3 网格，每个训练 8 个 epoch。结果表面是平滑且可解释的，而非不稳定。增加运动权重同时降低终端压力系统性地改善内容保持：在第 8 epoch，设定 (2.0, 10) 给出 CLIP 内容 0.8734，LPIPS 0.3720，EC 0.4373，相比默认 (1.0, 20) 设置的 CLIP 内容 0.8124，LPIPS 0.4477，EC 0.3937。相反，较弱的运动权重或较强的终端权重将模型推向更激进但内容忠实度更低的风格化；例如，(0.5, 30) 将 CLIP 内容降至 0.6926 并将 LPIPS 提高至 0.5538。此网格中最佳迁移 EC 检查点一致地出现在第 3 epoch 左右，再次表明协议暴露了




Figure 6: 40 轮类别权重扫描摘要。K2 平衡默认给予最佳 EC，而 K1 平衡默认在评估检查点中给予最佳原始 CLIP 风格。




Figure 7: 训练效率 Pareto 图（对数刻度）。我们在比较方法中达到最高 EC，同时位于最低训练成本区域。标记大小反映参数量。基线训练时间遵循表 1 中的外推值 ($\dagger$)。

宽阔的风格—内容前沿而非单一脆弱终点。

资源使用与可复现性

端到端推理和训练时间与主要指标一起列于表 1。所有时间在 NVIDIA RTX 4070 Laptop GPU (8 GB VRAM) 上使用相同的严格 750 协议测量。标记 $\dagger$ 的训练时间从单 epoch 探测外推。StyleID 按设计是无需训练的。

所有报告的严格 750 评估使用相同的域协议和预处理流水线。我们还在 40 轮扫描中评估每个 epoch，产出 320 个检查点评估。仅最终 epoch 选择可能隐藏风格—内容权衡：K2 平衡默认在第 3 epoch 达到最佳 EC，而 K1 平衡默认在第 8 epoch 达到最佳原始风格。为改进可复现性，每个训练运行存储解析的运行配置、源文件快照、检查点和逐 epoch CSV 日志。Python、NumPy、PyTorch 和 DataLoader 工作线程种子在每次运行中固定。

讨论与局限

我们不声称在所有方法中最大化原始风格识别；相反，我们声称在高效域级 regime 中具有显著更强的效率—质量权衡。核心结果是 LBM 保持近 SaMST 质量（CLIP 风格 0.716 vs. 0.719），改善 LPIPS 和 EC，训

练成本降低约 22 $\times$ ，并在核心迁移指标上优于更重的 S2WAT 基线——效率—质量的有利操作点。重要的是，此效率提升并非通过脱离质量前沿而购买：它伴随着比 SaMST 更好的 LPIPS/EC 和比 S2WAT 更强的核心权衡指标。

当前研究仍有若干局限。首先，风格表示是域级而非参考图像特定的；这使推理高效但限制复现独特单图像笔触模式或解决跨域原型冲突的能力。其次，Euler 积分故意简单，因此当潜在路径外推到更激进设置或更高分辨率时，离散化误差可能累积。第三，SWD 项使用启发式多尺度块投影而非精确传输求解器，因此桥视角应保持有界和实践性而非完全理论性。第四，尽管核心指标和效率分析对于比较基线已完成，但完整伪影诊断包仅针对子集重新运行。感知质量通过伪影敏感诊断而非主观投票评估，符合我们的可复现评估协议。最后，超越当前 256 基础协议的分辨率泛化仍有待验证。代码和严格 750 日志将在接受后发布以支持完全可复现性。未来工作应评估更丰富的域原型先验、受控积分范围、更高分辨率外推和更强的偏好导向评估，包括人类或评分标准 VLM 评估。

结论

我们提出了用于高效域级艺术迁移的 OT 耦合潜在流匹配。该方法结合三个互补目标：流匹配损失沿随机潜在桥监督时间条件速度场；终端切片 Wasserstein 匹配将积分终点拉向目标风格分布；运动正则化约束路径位移以保持内容。在严格的 750 输出评估下，所得 3.9M 参数模型达到竞争性 CLIP 风格（0.716）、高风格方法中最低的 LPIPS（0.451）、最佳 EC 得分（0.393），并显著降低比更重前馈基线的训练成本——域级艺术迁移的 Pareto 高效操作点。

References

- Bińkowski, M.; Sutherland, D. J.; Arbel, M.; and Gretton, A. 2018. Demystifying MMD GANs. In *International Conference on Learning Representations*.
- Chung, J.; Hyun, S.; and Heo, J.-P. 2024. Style Injection in Diffusion: A Training-free Approach for Adapting Large-scale Diffusion Models for Style Transfer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*.
- Cuturi, M. 2013. Sinkhorn Distances: Lightspeed Computation of Optimal Transport. *Advances in Neural Information Processing Systems*.
- Deng, Y.; Tang, F.; Dong, W.; Sun, W.; Huang, F.; and Xu, C. 2022. StyTr2: Image Style Transfer with Transformers. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*.
- Ding, K.; Ma, K.; Wang, S.; and Simoncelli, E. P. 2020. Image Quality Assessment: Unifying Structure and Texture Similarity. *IEEE Transactions on Pattern Analysis and Machine Intelligence*.
- Gatys, L. A.; Ecker, A. S.; and Bethge, M. 2016. Image Style Transfer Using Convolutional Neural Networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*.

- Gim, H.; Yoo, J.; and Uh, Y. 2024. Content-Adaptive Style Transfer: A Training-Free Approach with VQ Autoencoders. In *Proceedings of the Asian Conference on Computer Vision*.
- Heusel, M.; Ramsauer, H.; Unterthiner, T.; Nessler, B.; and Hochreiter, S. 2017. GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium. In *Advances in Neural Information Processing Systems*.
- Hong, K.; Jeon, S.; Yang, H.; Fu, J.; and Byun, H. 2023. AesPA-Net: Aesthetic Pattern-Aware Style Transfer Networks. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*.
- Huang, X.; and Belongie, S. 2017. Arbitrary Style Transfer in Real-time with Adaptive Instance Normalization. In *Proceedings of the IEEE International Conference on Computer Vision*.
- Huang, X.; Zhang, Z.; Zhang, J.; et al. 2024. AesFA: An Aesthetic Feature-Aware Arbitrary Neural Style Transfer. In *Proceedings of the AAAI Conference on Artificial Intelligence*.
- Ke, J.; Wang, Q.; Wang, Y.; Milanfar, P.; and Yang, F. 2021. MUSIQ: Multi-scale Image Quality Transformer. *Proceedings of the IEEE/CVF International Conference on Computer Vision*.
- Léonard, C. 2014. A Survey of the Schrödinger Problem and Some of Its Connections with Optimal Transport. *Discrete and Continuous Dynamical Systems - A*.
- Liu, Y.; et al. 2024. Pluggable Style Representation Learning for Multi-Style Transfer. In *Proceedings of the Asian Conference on Computer Vision*.
- Park, D. Y.; and Lee, K. H. 2019. Arbitrary Style Transfer with Style-Attentional Networks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*.
- Peyré, G.; and Cuturi, M. 2019. Computational Optimal Transport. *Foundations and Trends in Machine Learning*.
- Wright, M.; and Ommer, B. 2022. ArtFID: Quantitative Evaluation of Neural Style Transfer. *arXiv preprint arXiv:2207.12280*.
- Xia, W.; et al. 2024. S2WAT: Image Style Transfer via Hierarchical Vision Transformer Using Strips Window Attention. In *Proceedings of the AAAI Conference on Artificial Intelligence*.
- Yang, S.; Wu, T.; Shi, S.; Lao, S.; Gong, Y.; Cao, M.; Wang, J.; and Yang, Y. 2022. MANIQA: Multi-dimension Attention Network for No-Reference Image Quality Assessment. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*.
- Zhang, R.; Isola, P.; Efros, A. A.; Shechtman, E.; and Wang, O. 2018. The Unreasonable Effectiveness of Deep Features as a Perceptual Metric. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*.

可复现性检查清单

本文

- 包含对所引入 AI 方法的概要轮廓和/或伪代码描述：**是**。
- 明确区分意见、假设和推测与客观事实和结果：**是**。
- 为不熟悉读者提供标记清晰的教学参考文献以获得复制所需的背景：**是**。

本文是否做出理论贡献？ 否。本文使用有界的桥启发动机而非定理级别的理论声明。

本文是否依赖一个或多个数据集？ 是。

- 提供了选择所进行实验的数据集的动机：**是**。
- 本文引入的所有新数据集都包含在数据附录中：**NA**。
- 本文引入的所有新数据集将在论文发表时公开可用，并附有允许研究免费使用的许可证：**NA**。
- 从现有文献中提取的所有数据集都附有适当的引用：**是**。
- 从现有文献中提取的所有数据集都是公开可用的：**是**。
- 非公开可用的所有数据集都详细描述，并解释为什么公开替代方案在科学上不令人满意：**NA**。

本文是否包含计算实验？ 是。

- 本文说明了开发论文期间每个（超）参数尝试的次数和值范围，以及用于选择最终参数设置的标准：**部分**。
- 预处理数据所需的任何代码都包含在附录中：**否**。
- 进行和分析实验所需的所有源代码都包含在代码附录中：**否**。
- 进行和分析实验所需的所有源代码将在论文发表时公开可用，并附有允许研究免费使用的许可证：**部分**。
- 实现新方法的所有源代码都有注释，详细说明实现，并引用论文中每个步骤的来源：**部分**。
- 如果算法依赖随机性，则以足够允许结果复制的方式描述设置种子的方法：**部分**。
- 本文指定了用于运行实验的计算基础设施，包括硬件/软件细节：**部分**。
- 本文正式描述了使用的评估指标并解释选择这些指标的动机：**是**。
- 本文说明了用于计算每个报告结果的算法运行次数：**是**。
- 实验分析超越单维性能总结，包括变化、置信度或其他分布信息的度量：**是**。
- 使用适当的统计检验判断任何改进或性能下降的意义：**是**（配对 bootstrap，5000 次重采样，在实验节中报告）。
- 本文列出实验中每个模型/算法使用的所有最终（超）参数：**部分**。